

Prognose individuellen Mobilitätsverhaltens

auf Basis eines mit Bewegungsdaten trainierten Machine-Learning-Modells


Achim Baumgärtner | Betreuung: Gian Ledl-Truöl, Prof. Dr. Sonntag | Fakultät Informatik und Informationstechnik, Hochschule Esslingen

AIM Angewandte Informatik



Motivation

Der wachsende Anteil erneuerbarer Energien erzeugt ein Speicherproblem: überschüssiger Strom lässt sich bislang kaum wirtschaftlich speichern. **Elektrofahrzeuge** können als mobile, verteilte Speicher dienen und über *Vehicle-to-Grid* (V2G) Energie ins Netz zurückspeisen. Voraussetzung ist, dass bekannt ist, *wann* ein Fahrzeug genutzt wird und wann es dem Netz zur Verfügung steht – eine Fehleinschätzung kann bis zur Nichtverfügbarkeit des Fahrzeugs führen.



Problem & Forschungslücke

Bestehende Arbeiten behandeln überwiegend das *Ladeverhalten* oder *aggregierte* Gruppen. Das **individuelle** Fahrverhalten einzelner Fahrzeuge wird kaum modelliert, obwohl es stark heterogen ist [1]. Zudem fehlt ein einheitliches Datenformat: Datensätze unterscheiden sich erheblich in Schema, Auflösung und Qualität.

Forschungsfragen

- Wie zuverlässig lässt sich individuelles Mobilitätsverhalten über bis zu sieben Tage vorhersagen, und wie unterscheiden sich die Lernverfahren? Welchen Einfluss hat die **Datenqualität** – getrennt vom **Algorithmus**?
- Welche Anforderungen an die Datengrundlage ergeben sich, und wie lässt sich ihre Qualität bewerten?

Ziele

- ein zuverlässiges Prognosemodell für das individuelle Mobilitätsverhalten (1–7 Tage),
- Vergleich mehrerer Lernverfahren hinsichtlich Genauigkeit,
- Trennung des Daten- vom Algorithmus-Effekt,
- kalibrierte Unsicherheit (P10/P90) als Entscheidungsgrundlage für die Netzsteuerung.

Daten

In Ihrem ursprünglichen Format waren die Daten nicht zu verwerten und mussten daher einheitlich verarbeitet werden. Im Moment werden fünf heterogene Quellen werden über einen Adapter auf ein einheitliches Schema (**vehicle_id**, **timestamp**, **driving**) gebracht:


Quelle	Charakter
emobpy	synthetische BEV-Profil [2]
real_world_ev	reale EV-Felddaten [3]
VED	Fahrzeug-Energiedaten [4]
routine	regelbasierte Referenz
YJMob100K	menschl. Bewegungsdaten (Kontrast) [5]

datetime,in_use,location,distance_km,consumption_kwh
2020-01-01 00:00:00,0,home,0.0,0.0
2020-01-01 01:00:00,0,home,0.0,0.0
2020-01-01 02:00:00,0,home,0.0,0.0
2020-01-01 03:00:00,0,home,0.0,0.0
2020-01-01 04:00:00,0,home,0.0,0.0
2020-01-01 05:00:00,0,home,0.0,0.0
2020-01-01 06:00:00,1,driving,15.0,3.377

heterogene Rohdatenform (emobpy)


Methodik

Zwei überwachte Teilaufgaben: **Klassifikation** (fährt vs. geparkt, pro Stunde) und **Regression** (Abfahrts-/Rückkehrzeit). Aus den Rohdaten werden Kalender-, Lag- und Rolling-Merkmale abgeleitet; Lags respektieren die Fahrzeuggrenzen (kein Datenleck).



Verarbeitungs-Pipeline der Mobilitätsdaten


Als Verfahren dienen baumbasierte Ensembles – **Random Forest** [6] als Baseline und **Gradient Boosting (LightGBM)**. Beide liefern Unsicherheitsbänder (P10/P90); ein autoregressives Monte-Carlo-Rollout erzeugt stundengenaue Prognosen. Das starke Klassenungleichgewicht (Fahrzeuge stehen meist) wird durch **Klassengewichtung** ausgeglichen.



Entscheidungsbaum: Split nach Gini-Unreinheit

Evaluationsdesign & Ergebnis

Eine **Kreuzvalidierungs-Matrix** trainiert je Modell auf einer Quelle und testet auf *allen*. Da Algorithmus und Merkmale konstant bleiben, isoliert sie den **Daten-** vom **Algorithmus-Effekt**. Alle Splits sind **zeitlich** (Vergangenheit → Training, Zukunft → Test), nie zufällig.



F1 der 5×5-Kreuzvalidierung

Die Diagonale (In-Domain) ist meist am stärksten. VED bleibt schwach (nur Fahrt-Logs, rekonstruierte Parkzeiten), während leicht prognostizierbare Quellen mit hoher Aktiv-Rate (**routine**, **YJMob**) hohe Werte erreichen – der **Einfluss der Datenquelle** wird klar sichtbar.

Fazit & Ausblick

Die Arbeit schafft die Grundlage für eine fahrzeugbasierte, vorausschauende Steuerung von Energieflüssen. Da menschliche Mobilität eine prinzipielle Vorhersagbarkeitsgrenze besitzt [7], steht nicht die perfekte Prognose im Fokus, sondern **belastbare, unsicherheitsbewusste** Aussagen. Ausblick: sequenzielle Modelle (LSTM, Transformer) und Übertragbarkeit auf neue Nutzer.

Quellen

- [1] Ji et al., *Rethinking the Regularity in Mobility Patterns*, T. in GIS, 2023.
- [2] Gaete-Morales et al., *emobpy*, Zenodo, 2020.
- [3] Pozzato et al., *Real-World EV Field Data*, Mendeley, 2023.
- [4] Oh et al., *Vehicle Energy Dataset (VED)*, IEEE T-ITS, 2022.
- [5] Yabe et al., *YJMob100K*, Scientific Data, 2024.
- [6] Breiman, *Random Forests*, Machine Learning, 2001.
- [7] Song et al., *Limits of Predictability in Human Mobility*, Science, 2010.
- [8] PV-Icon: *Cartoon Solar Panels*, Pngtree, pngtree.com/freepng/cartoon-solar-panels_2067893.html