

Prognose individuellen Mobilitätsverhaltens

auf Basis eines mit Bewegungsdaten trainierten Machine-Learning-Modells

Achim Baumgärtner | Betreuung: Gian Ledl-Truöl, Prof. Dr. Sonntag | Fakultät Informatik und Informationstechnik, Hochschule Esslingen

Motivation

Der wachsende Anteil erneuerbarer Energien erzeugt ein Speicherproblem: überschüssiger Strom lässt sich bislang kaum wirtschaftlich speichern. **Elektrofahrzeuge** können als mobile, verteilte Speicher dienen und über *Vehicle-to-Grid* (V2G) Energie ins Netz zurückspeisen. Voraussetzung ist, dass bekannt ist, *wann* ein Fahrzeug genutzt wird und *wann* es dem Netz zur Verfügung steht – eine Fehleinschätzung kann bis zur Nichtverfügbarkeit des Fahrzeugs führen.

Problem & Forschungslücke

Bestehende Arbeiten behandeln überwiegend das *Ladeverhalten* oder *aggregierte* Gruppen. Das **individuelle** Fahrverhalten einzelner Fahrzeuge wird kaum modelliert, obwohl es stark heterogen ist [1]. Zudem fehlt ein einheitliches Datenformat: Datensätze unterscheiden sich erheblich in Schema, Auflösung und Qualität.

Forschungsfragen

- Wie zuverlässig lässt sich individuelles Mobilitätsverhalten über bis zu sieben Tage vorhersagen, und wie unterscheiden sich die Lernverfahren? Welchen Einfluss hat die **Datenqualität** – getrennt vom **Algorithmus**?
- Welche Anforderungen an die Datengrundlage ergeben sich, und wie lässt sich ihre Qualität bewerten?

Ziele

- ein zuverlässiges Prognosemodell für das individuelle Mobilitätsverhalten (1–7 Tage),
- Vergleich mehrerer Lernverfahren hinsichtlich Genauigkeit,
- Trennung des Daten- vom Algorithmus-Effekt,
- kalibrierte Unsicherheit (P10/P90) als Entscheidungsgrundlage für die Netzsteuerung.

Daten

Fünf heterogene Quellen werden über einen Adapter auf ein einheitliches Schema (**vehicle_id**, **timestamp**, **driving**) gebracht:


Quelle	Charakter
emobpy	synthetische BEV-Profilе [2]
real_world_ev	reale EV-Felddaten [3]
VED	Fahrzeug-Energiedaten [4]
routine	regelbasierte Referenz
YJMob100K	menschl. Bewegungsdaten (Kontrast) [5]

```
datetime,in_use,location,distance_km,consumption_kwh
2020-01-01 00:00:00,0,home,0.0,0.0
2020-01-01 01:00:00,0,home,0.0,0.0
2020-01-01 02:00:00,0,home,0.0,0.0
2020-01-01 03:00:00,0,home,0.0,0.0
2020-01-01 04:00:00,0,home,0.0,0.0
2020-01-01 05:00:00,0,home,0.0,0.0
2020-01-01 06:00:00,1,driving,15.0,3.377
```

Beispiel: heterogene Rohdatenformate


Methodik

Zwei überwachte Teilaufgaben: **Klassifikation** (fährt vs. geparkt, pro Stunde) und **Regression** (Abfahrts-/Rückkehrzeit). Aus den Rohdaten werden Kalender-, Lag- und Rolling-Merkmale abgeleitet; Lags respektieren die Fahrzeuggrenzen (kein Datenleck).



Verarbeitungs-Pipeline der Mobilitätsdaten


Als Verfahren dienen baumbasierte Ensembles – **Random Forest** [6] als Baseline und **Gradient Boosting (LightGBM)**. Beide liefern Unsicherheitsbänder (P10/P90); ein autoregressives Monte-Carlo-Rollout erzeugt stundengenaue Prognosen. Das starke Klassenungleichgewicht (Fahrzeuge stehen meist) wird durch **Klassengewichtung** ausgeglichen.



Entscheidungsbaum: Split nach Gini-Unreinheit

Evaluationsdesign & Ergebnis

Eine **Kreuzvalidierungs-Matrix** trainiert je Modell auf einer Quelle und testet auf *allen*. Da Algorithmus und Merkmale konstant bleiben, isoliert sie den **Daten-** vom **Algorithmus-Effekt**. Alle Splits sind **zeitlich** (Vergangenheit → Training, Zukunft → Test), nie zufällig.



F1 der 5×5-Kreuzvalidierung (Zeile: trainiert, Spalte: getestet)

Die Diagonale (In-Domain) ist meist am stärksten. VED bleibt schwach (nur Fahrt-Logs, rekonstruierte Parkzeiten), während leicht prognostizierbare Quellen mit hoher Aktiv-Rate (**routine**, YJMob) hohe Werte erreichen – der **Einfluss der Datenquelle** wird klar sichtbar.

Fazit & Ausblick

Die Arbeit schafft die Grundlage für eine vorausschauende, fahrzeugscharfe Steuerung von Energieflüssen. Da menschliche Mobilität eine prinzipielle Vorhersagbarkeitsgrenze besitzt [7], steht nicht die perfekte Prognose im Fokus, sondern **belastbare, unsicherheitsbewusste** Aussagen. Ausblick: sequenzielle Modelle (LSTM, Transformer) und Übertragbarkeit auf neue Nutzer.

Quellen

- [1] Ji et al., *Rethinking the Regularity in Mobility Patterns*, T. in GIS, 2023.
- [2] Gaete-Morales et al., *emobpy*, Zenodo, 2020.
- [3] Pozzato et al., *Real-World EV Field Data*, Mendeley, 2023.
- [4] Oh et al., *Vehicle Energy Dataset (VED)*, IEEE T-ITS, 2022.
- [5] Yabe et al., *YJMob100K*, Scientific Data, 2024.
- [6] Breiman, *Random Forests*, Machine Learning, 2001.
- [7] Song et al., *Limits of Predictability in Human Mobility*, Science, 2010.