

Hochschule Esslingen

Fakultät für Informatik

Masterarbeit

Prognose individuellen Mobilitätsverhaltens auf Basis eines mit Bewegungsdaten trainierten Machine-Learning-Modells

Achim Baumgärtner

Matrikelnummer: 766010

Erstgutachter: Prof. Dr. Sonntag

Zweitgutachter: Prof. Dr. Schober

Esslingen am Neckar, 18. Juli 2026

Kurzfassung

Die Auswertung fahrzeugspezifischer Daten ermöglicht es, bei kontinuierlichen Nutzungsmustern das Bewegungsverhalten vorherzusagen. Dadurch kann bidirektionales Laden effizienter eingesetzt werden, was sowohl die Fahrzeughalter als auch das Stromnetz entlastet. Ziel ist es, durch Machine Learning ein Modell zu entwerfen, das möglichst genau individuelles Verkehrsverhalten prognostizieren kann. Zu bewerkstelligen ist dieses Vorhaben durch eine Ablationsstudie; Es werden auf Basis einer Datengrundlage Modelle erstellt und untereinander verglichen, wodurch die Annahme entsteht, dass ein Modell besser abschneiden wird, als die anderen. Das stärkste Modell wird dann weiter entwickelt um die Ergebnisse zu optimieren und somit die Zuverlässigkeit und den Beitrag zum Stromnetz von elektrischen Fahrzeugen zu erhöhen.

Schlüsselwörter: Künstliche Intelligenz, Machine Learning, Prognose, Fahrzeugnutzung, Elektromobilität, Bidirektionales Laden, Random Forest, LightGBM

Inhaltsverzeichnis

Kurzfassung	i
Abbildungsverzeichnis	iv
Tabellenverzeichnis	0
1. Einleitung	1
1.1. Motivation	1
1.2. Problemstellung	2
1.3. Zielsetzung	3
1.4. Forschungsfragen	3
1.5. Aufbau der Arbeit	5
2. Theoretische Grundlagen	6
2.1. Mobilitätsdaten	6
2.2. Verarbeitung von Mobilitätsdaten	7
2.3. Machine Learning	9
2.3.1. Überwachtes Lernen	10
2.3.2. Merkmale und Feature Engineering	10
2.3.3. Training	11
2.3.4. Generalisierung	11
2.3.5. Validierung	12
2.3.6. Bewertungsmetriken	13
2.3.7. Entscheidungsbäume	13
2.3.8. Random Forest	17
2.3.9. Light Gradient Boosting Machine	17
2.3.10. Unsicherheit und Quantilsregression	17
2.3.11. Long Short-Term Memory	18
2.4. Stand der Forschung	19
2.4.1. Verwandte Arbeiten	20
3. Methodik	26
3.1. Forschungsdesign	26

3.2. Untersuchungsablauf	27
3.3. Datengrundlage und Quellen	29
3.4. Feature Engineering	33
3.5. Modellauswahl	33
3.6. Experimentaldesign	33
3.7. Bewertung	33
4. Implementierung	34
4.1. Anforderungen	34
4.2. Systemarchitektur	35
4.3. Technologieauswahl	35
4.4. Umsetzung	35
4.5. Herausforderungen	36
5. Evaluation	37
5.1. Evaluationsdesign	37
5.2. Testumgebung	37
5.3. Ergebnisse	37
6. Diskussion	39
6.1. Interpretation der Ergebnisse	39
6.2. Vergleich mit verwandten Arbeiten	39
6.3. Limitationen	39
6.4. Implikationen	40
7. Fazit und Ausblick	41
7.1. Beantwortung der Forschungsfragen	41
7.2. Ausblick	41
Literaturverzeichnis	42
A. Anhang	45
A.1. Zusätzliche Abbildungen	45
A.2. Zusätzliche Tabellen	45
A.3. Quellcode	45
Eidesstattliche Erklärung	46

Abbildungsverzeichnis

2.1. Beispielhafte Auszüge zweier Mobilitätsdatensätze.	6
2.2. Generalisierte Pipeline zur Verarbeitung von Mobilitätsdaten.	7
2.3. Teilbereiche des maschinellen Lernens mit beispielhaften Anwendungen (Wuttke 2024).	9
2.4. Entscheidungsbaum mit Aufteilungskriterien (nach Schilli 2017).	14
2.5. Bagging: Aus den Trainingsdaten werden N Bootstrap-Stichproben gezogen, auf denen jeweils ein Baum trainiert wird; deren Vorhersagen werden zu einem Ensemble aggregiert (ResearchGate 2022).	15
2.6. Boosting: Die Modelle werden nacheinander trainiert, wobei jedes folgende Modell auf den Fehlern des vorherigen Modells basiert (Re- searchGate 2021).	16
2.7. Baumwachstum in Ensemble-Verfahren (ScienceDirect 2026).	16
2.8. (a) Heteroskedastisches Prognoseband: Median (P50) und 80 %-Intervall (P10–P90), dessen Breite mit der Streuung wächst. (b) ρ_τ für $\tau =$ 0,1/0,5/0,9; die Asymmetrie schiebt die Schätzung an das jeweilige Quantil (Koenker u. a. 1978).	18
2.9. Aufbau einer LSTM-Zelle: Der Zellzustand C_t wird durch Forget-, Input- und Output-Gate gesteuert, die per σ - und tanh-Aktivierung festlegen, was aus dem Gedächtnis verworfen, neu geschrieben und ausgelesen wird (dida 2026).	19
2.10. Verteilung der Fahrdistanz (a) und der Abfahrtszeit des ersten Tages- trips (b) nach Wochentag (Lindroth u. a. 2024).	22
2.11. Zeitliche Muster der Ladeanfragen im verwendeten Datensatz (Sanami u. a. 2025).	24
3.1. Variablenstruktur des Forschungsdesigns: zwei veränderliche unab- hängige Variablen (Daten, Algorithmus) und eine abhängige Variable (Prognosegüte). Konstante Hyperparameter und Trainingsprotokolle wirken als Kontrollvariablen.	27

3.2. Schematischer Workflow der Methodik: von den fünf Datenquellen über den geteilten Feature-Kern und die beiden Aufgabenmodelle bis zum Experimentaldesign und der Bewertung.	30
--	----

Tabellenverzeichnis

1.1. Forschungsfragen der Arbeit.	4
2.1. Phasen der Mobilitätsdaten-Pipeline	8
2.2. Charakterisierung von Anpassungen anhand von Fehlerwerten Géron 2022.	12
2.3. Zentrale Forschungssektionen im Umfeld der individuellen Fahrzeug- nutzungsprognose.	20
2.4. Fünf Fahrertypen des Individualverkehrs nach Ji u. a. (2023).	25
3.1. Hypothesen zu den Forschungsfragen.	28
3.2. Übersicht der fünf Datenquellen und ihrer identifizierenden Eigen- schaften.	31
4.1. Anforderungen	34
5.1. Modell (RandomForest) im Vergleich zu naiven Baselines, In-Distribution je Datenquelle auf demselben zeitlichen Test-Split. Majority = „immer geparkt“; Persistenz-168 = gleiche Stunde der Vorwoche; Klimatologie = $P(\text{fahren} \mid \text{Wochentag}, \text{Stunde})$ aus dem Trainingsteil.	38
5.2. In-Distribution-Gütemaße des Driving-Classifiers je Datenquelle (Acc. = Accuracy, ROC = ROC-AUC, PR = PR-AUC, Brier = Brier-Score, Aktiv-Rate = Anteil der Fahrstunden). Beide Algorithmen nutzen denselben Feature-Satz.	38

1. Einleitung

Die Elektromobilität ist ein immer wichtiger werdendes Thema. Sie trägt zur Reduzierung von Treibhausgasemissionen bei, verringert die Abhängigkeit zu fossilen Brennstoffen und somit auch wirtschaftliche Abhängigkeiten. Gleichzeitig bietet sie eine neue Möglichkeit bei der Energieversorgung.

Die Möglichkeit bei der Energieversorgung ist hier besonders interessant. Fahrzeuge, die mit Strom betrieben werden, können nicht nur als Verbraucher betrachtet werden, sondern auch als Energiespeicher. Elektrofahrzeuge können also nicht nur Energie aufnehmen, sondern diese auch wieder abgeben, was besonders im Kontext von erneuerbaren Energien von großer Bedeutung ist.

Im Moment bestehen noch kaum rentable Möglichkeiten, überschüssige Energie aus erneuerbaren Quellen zu speichern, weshalb dem Thema eine besondere Relevanz zukommt: Durch eine zuverlässige Speicherung könnte Energie auch dann genutzt werden, wenn Solar- oder Windanlagen nicht aktiv erzeugen. Damit ließe sich der Anteil erneuerbarer Energien an der Versorgung deutlich erhöhen, was ein wichtiger Beitrag zur Energiewende wäre.

Jedoch bringt eine Speicherung von Energie in Elektrofahrzeugen einen geringfügigen Mehrwert - ökonomisch wie auch ökologisch - wenn diese nicht zuverlässig gesteuert wird. Es wird ein System benötigt, das die intelligente Steuerung von Energieflüssen zwischen Fahrzeug und Stromnetz ermöglicht. Eine intelligente Steuerung ist nur möglich, wenn das Nutzerverhalten identifiziert werden kann. Es muss also ein System entworfen werden, das eine zuverlässige Vorhersage über das Mobilitätsverhalten des Nutzers ermöglicht.

1.1. Motivation

In dieser Arbeit wird untersucht, inwiefern sich das Nutzungsverhalten von Elektrofahrzeugen vorhersagen lässt, um potentiell den Energiefluss zwischen Fahrzeug und Stromnetz zu optimieren. Voraussetzung hierfür ist die Verfügbarkeit von V2G

(Vehicle-to-Grid), also der Fähigkeit von Elektrofahrzeugen, Energie nicht nur aufzunehmen, sondern auch wieder ans Stromnetz abzugeben. Obwohl V2G zunehmend an Präsenz gewinnt, bestehen in der praktischen Anwendung weiterhin große Lücken. Ein zentraler Baustein für das effiziente Zusammenwirken von Elektrofahrzeugen und Stromnetz ist ein zuverlässiges Vorhersagemodell des Mobilitätsverhaltens: Es erlaubt, Lade- und Entladezyklen so zu steuern, dass sowohl die Effizienz der mobilen Akkumulatoren als auch die Auslastung des Netzes optimiert werden. Entscheidend ist dabei die Zuverlässigkeit der Vorhersage, um ein fehlerloses System gewährleisten zu können.

1.2. Problemstellung

Die größte Hürde stellt eine stabile Datengrundlage dar. Da der Anwendungsfall sehr anspruchsvoll und dynamisch ist, lässt er sich mit bestehenden Ansätzen bislang nur unzureichend abbilden. Typischerweise erzielen Machine Learning Modelle sehr gute Ergebnisse bei dieser Art von Vorhersageproblemen. Voraussetzung dafür ist allerdings eine hochqualitative Datenbasis, denn Fehleinschätzungen können zu einer fehlerhaften Energiieverwaltung und im schlimmsten Fall zur Nichtverfügbarkeit des Fahrzeugs führen. Es müssen also verlässliche Daten über das Mobilitätsverhalten erhoben oder von Dritten bezogen werden. Da Qualität in diesem Bereich nicht genau definiert ist, gilt es dies an bestimmten Kriterien und Werten festzulegen.

In Betrachtung der existierenden wissenschaftlichen Literatur besteht im Moment ein Mangel an Studien, die sich explizit mit dem Mobilitätsverhalten von Individuen und der Erstellung von Prognosemodellen für diesen Zweck beschäftigen. Es gibt wertvolle Studien, die sich mit dem Mobilitätsverhalten von Gruppen beschäftigen, jedoch liefern diese wenig Aufschluss darüber, wie sich der Individualverkehr vorhersagen lässt. Damit künftig eine intelligente Steuerung von Energieflüssen möglich wird, müssen zuverlässige Vorhersagemodelle entwickelt werden, die auf hochqualitativen Daten zum individuellen Mobilitätsverhalten basieren.

Bisherige Arbeiten zur Prognose im Mobilitäts- und Energiekontext konzentrieren sich überwiegend auf den Ladezeitpunkt, die Leistung oder den letztendlichen Ladezustand sowie auf aggregiertes Nutzungsverhalten ganzer Gruppen. Das individuelle Fahr- und Nutzungsverhalten einzelner Fahrzeuge wird dabei kaum modelliert, obwohl gerade dieses für eine genaue Steuerung bzw. Vorhersage von Nöten ist. Wo individuelles Fahrverhalten betrachtet wird, ist es zwischen den Fahrern stark heterogen, sodass ein einzelnes, übergreifendes Modell nicht den kompletten Kontext erfasst; zugleich ist die Datenbasis der wenigen einschlägigen Studien häufig nicht ausreichend oder

– wie bei synthetisch erzeugten Profilen – nicht zuverlässig repräsentativ für reale Mobilitätsdaten. Eine ausführliche Einordnung der relevanten Forschungsstränge und die daraus abgeleitete Forschungslücke finden sich in Abschnitt 2.4.

1.3. Zielsetzung

Das Ziel der Arbeit ist es, zuverlässige Modelle zur Prognose für individuelles Mobilitätsverhalten zu entwickeln. Die Modelle sollen den Zweck erfüllen, genauer Uhrzeiten vorhersagen zu können, wann ein Fahrzeug fährt und wann es parkt. Beispielsweise soll ein Modell zwischen ein und sieben Tage lange Prognosen erstellen können. Dazu sind die erhobenen Daten qualitativ zu bewerten und wenn nötig, aus Datenschutzgründen zu anonymisieren. Auf dieser Grundlage werden Modelle erstellt, die das Mobilitätsverhalten von Nutzern möglichst genau vorhersagen können. Des Weiteren soll Gegenstand der Arbeit sein, die Vorhersagegenauigkeit verschiedener Modelle zu vergleichen und deren Einflussfaktoren zu quantifizieren. Die Ergebnisse sollen dazu beitragen, eine intelligente Steuerung von Energieflüssen zwischen Fahrzeug und Stromnetz zu ermöglichen, um so die Nutzung von erneuerbaren Energien zu verbessern und eine wichtige Rolle bei der Energiewende zu spielen.

1.4. Forschungsfragen

Im Folgenden werden die Forschungsfragen der Arbeit vorgestellt, die in Tabelle 1.1 zusammengefasst sind. Die Forschungsfragen sind in zwei große Themenbereiche gegliedert: Mobilitätsprognose und Mobilitätsdaten. Der erste Bereich beschäftigt sich mit der Vorhersage des individuellen Mobilitätsverhaltens, während der zweite Bereich die Anforderungen an die Datengrundlage und deren Qualität untersucht.

Tabelle 1.1.: Forschungsfragen der Arbeit.

Nr.	Forschungsfrage
Mobilitätsprognose	
FF1	Wie zuverlässig lässt sich das individuelle Mobilitätsverhalten einzelner Fahrzeuge über einen Horizont von bis zu sieben Tagen vorhersagen?
FF1.1	Wie unterscheiden sich verschiedene Verfahren des maschinellen Lernens hinsichtlich ihrer Vorhersagegenauigkeit?
FF1.1.1	Welchen Einfluss hat die Datenqualität bzw. -quelle auf die Prognosegüte – getrennt vom Einfluss des gewählten Algorithmus?
FF1.2	Welche Merkmale beeinflussen das individuelle Mobilitätsverhalten am stärksten?
Mobilitätsdaten	
FF2	Welche Anforderungen an die Datengrundlage ergeben sich daraus?
FF2.1	Wie wirken sich Aufbereitung und eine aus Datenschutzgründen notwendige Anonymisierung auf die Nutzbarkeit der Daten aus?
FF2.2	Wie lässt sich die Qualität der Daten bewerten?

1.5. Aufbau der Arbeit

Die vorliegende Arbeit ist wie folgt aufgebaut:

Kapitel 1 führt in das Thema ein und fasst den Kerninhalt zusammen.

Kapitel 2 erläutert die theoretischen Grundlagen, die für das Verständnis dieser Arbeit notwendig sind.

Kapitel 3 beschreibt die gewählte Methodik und das Vorgehen.

Kapitel 4 stellt die Implementierung der entwickelten Lösung vor.

Kapitel 5 präsentiert die Evaluation und die erzielten Ergebnisse.

Kapitel 6 diskutiert die Ergebnisse und deren Bedeutung.

Kapitel 7 fasst die Arbeit zusammen und gibt einen Ausblick auf zukünftige Arbeiten.

2. Theoretische Grundlagen

Dieses Kapitel legt die Grundlagen, auf denen die folgende Methodik aufbaut; Sowohl Begrifflichkeiten, als auch thematische Grundlagen werden erläutert. Als erstes wird festgelegt, was genau Mobilitätsdaten sind und wann sie relevant sind (Abschnitt 2.1). Darauf folgt der Blick darauf, wie Mobilitätsdaten verarbeitet werden und anhand welcher Kriterien sich ihre Qualität bewerten lässt (Abschnitt 2.2). Der vorletzte Punkt erläutert Machine Learning und wieso die Verwendung in dieser Arbeit unerlässlich ist. Als letztes ordnet Abschnitt 2.4 den aktuellen Stand der Forschung ein und arbeitet die Forschungslücke heraus, von der sich diese Arbeit in Abschnitt 2.4.1 abgrenzt.

2.1. Mobilitätsdaten

```
datetime,in_use,event,soc_pct,volt_v,curr_a,temp_c
2019-12-13 21:00:00,1,driving,58.8,412.8,-98.64,23.31
2019-12-13 22:00:00,1,driving,85.0,441.4,-47.771,27.52
2019-12-13 23:00:00,1,driving,86.0,436.76,37.899,28.5
2019-12-14 00:00:00,0,parked,86.0,436.76,37.899,28.5
2019-12-14 01:00:00,0,parked,86.0,436.76,37.899,28.5
2019-12-14 02:00:00,0,parked,86.0,436.76,37.899,28.5
2019-12-14 03:00:00,0,parked,86.0,436.76,37.899,28.5
2019-12-14 04:00:00,0,parked,86.0,436.76,37.899,28.5
```

(a) Datensatz: Cars Real World Electric (Pozzato u. a. 2023)

```
datetime,in_use,location,distance_km,consumption_kwh
2020-01-01 00:00:00,0,home,0.0,0.0
2020-01-01 01:00:00,0,home,0.0,0.0
2020-01-01 02:00:00,0,home,0.0,0.0
2020-01-01 03:00:00,0,home,0.0,0.0
2020-01-01 04:00:00,0,home,0.0,0.0
2020-01-01 05:00:00,0,home,0.0,0.0
2020-01-01 06:00:00,1,driving,15.0,3.377
```

(b) Datensatz: emobpy (Gaete-Morales u. a. 2020)

Abbildung 2.1.: Beispielhafte Auszüge zweier Mobilitätsdatensätze.

Wenn von Mobilitätsdaten gesprochen wird, ist im digitalen Rahmen meist die Rede von Dateien, die Informationen in chronologischer Abfolge enthalten. Diese Daten

können in den unterschiedlichsten Formaten auftreten – mit beliebig vielen Einträgen und beliebig vielen Informationen pro Eintrag – und sind nicht zwingend homogen. Für das individuelle Fahr- und Nutzungsverhalten einzelner Fahrzeuge existiert – anders als für ÖPNV- oder Sharing-Daten – kein etabliertes Standardformat. Daraus folgt, dass sich Datensätze aus verschiedenen Studien erheblich in Schema und Granularität unterscheiden: In Abbildung 2.1a finden sich neben einem üblichen Zeitstempel nur die physikalischen Messwerte und kaum Informationen über das Fahrzeug oder den Zweck des Aufenthalts. Abbildung 2.1b enthält dagegen die Aktivität, gefahrene Distanz und den Energiekonsum. Für diese Arbeit sind jedoch nur wenige Felder unabdingbar – im Wesentlichen Zeitstempel und Fahr- bzw. Parkzustand –, und diese sind in beiden Datensätzen enthalten. Trotz ihres erheblichen Unterschieds sind daher beide valide und relevant.

2.2. Verarbeitung von Mobilitätsdaten

Die Mobilitätsdaten bilden einen Hauptaspekt dieser Arbeit, da sie die Grundlage für das Training und die Validierung der Modelle darstellen.




Abbildung 2.2.: Generalisierte Pipeline zur Verarbeitung von Mobilitätsdaten.

Abbildung 2.2 zeigt den Ablauf, den die Daten von der Recherche bis zur Nutzung durchlaufen; jeder der sechs Abschnitte umfasst dabei mehrere Teilschritte. Tabelle 2.1 fasst diese je Phase zusammen, die folgenden Absätze erläutern sie.

Recherche: Der erste Schritt ist die Identifikation geeigneter Datenquellen. Dabei ist zu beachten, dass Mobilitätsdaten allein noch keine Relevanz bedeuten: Die Daten müssen einer Studie entstammen, die für die individuelle Fahrzeugnutzungsprognose einschlägig ist. Erst nach hinreichender Prüfung dieser thematischen Eignung werden die Daten weiterverfolgt.

Phase	Wesentliche Teilschritte
1 – Recherche	Identifikation relevanter Studien und Datensätze; Prüfung der thematischen Eignung.
2 – Beschaffung	Bezug der Daten unter Beachtung rechtlicher und datenschutzrechtlicher Vorgaben.
3 – Bewertung	Beurteilung der Datenqualität anhand definierter Kriterien.
4 – Verarbeitung	Bereinigung, Überführung in ein einheitliches Schema, Feature-Engineering und gegebenenfalls Anonymisierung.
5 – Modellierung	Training und Validierung der Klassifikations- und Prognosemodelle.
6 – Nutzung	Anwendung der Modelle zur Vorhersage und Bereitstellung der Ergebnisse für nachfolgende Systeme.

Tabelle 2.1.: Phasen der Mobilitätsdaten-Pipeline

Beschaffung: Geeignete Daten müssen anschließend bezogen werden, durch Download offener Datensätze, Anfrage bei datenhaltenden Dritten oder eigene Erhebung. Bereits hier sind rechtliche und datenschutzrechtliche Rahmenbedingungen zu berücksichtigen, da personenbezogene Bewegungsdaten besonders schützenswert sind. Da jedoch der zeitliche Rahmen der Arbeit nicht für eigene Erhebung ausreicht, sind die Daten auf öffentlich zugängliche oder Kooperationen beschränkt.

Bewertung: Vor der Weiterverarbeitung wird die Qualität der Daten beurteilt. Da der Begriff der Datenqualität in diesem Bereich nicht eindeutig definiert ist, wird er an konkreten Kriterien festgemacht: Vollständigkeit, zeitliche Auflösung und Umfangänglichkeit der Daten. Diese Bewertung entscheidet letztendlich darüber, ob ein Datensatz für ein zuverlässiges Modell geeignet ist.

Verarbeitung: Die als geeignet bewerteten Daten werden bereinigt und in ein einheitliches Schema überführt, sodass Quellen unterschiedlicher Herkunft vergleichbar werden. Anschließend werden aus den Rohdaten die für die Modelle benötigten Merkmale abgeleitet und bei Bedarf erfolgt zudem eine Anonymisierung.

Modellierung: Auf der aufbereiteten Datenbasis werden die Modelle trainiert und validiert. Dieser Schritt umfasst sowohl die Klassifikation des Fahrverhaltens als auch die eigentliche Prognose der Fahrzeugnutzung.

Nutzung: Abschließend werden die trainierten Modelle angewendet, um das individuelle Mobilitätsverhalten vorherzusagen. Die daraus gewonnenen Prognosen werden dokumentiert und bereitgestellt. Sie liefern die Grundlage für Vorhersagen in der Fahrzeugnutzung und damit ein weiterer Schritt hin zu einem intelligenten Energiesystem.

2.3. Machine Learning




Abbildung 2.3.: Teilbereiche des maschinellen Lernens mit beispielhaften Anwendungen (Wuttke 2024).

Das Prinzip des maschinellen Lernens besteht darin, einem Computer ein gewünschtes Verhalten anhand von Beispieldaten beizubringen, anstatt es durch einen fest vorgegebenen, regelbasierten Algorithmus explizit zu programmieren (Bishop 2006). Das Modell erkennt dabei statistische Muster in den Trainingsdaten und nutzt diese, um Vorhersagen für bislang ungesehene Eingaben zu treffen. Der Vorteil gegenüber einem starren Algorithmus liegt darin, dass komplexe Zusammenhänge – wie das indi-

viduelle Mobilitätsverhalten – erlernt werden können, ohne dass sie vorab vollständig bekannt sein müssen.

Häufig wird maschinelles Lernen mit künstlichen neuronalen Netzen gleichgesetzt, deren Aufbau vom menschlichen Gehirn inspiriert ist. Neuronale Netze bilden jedoch nur eine von vielen Verfahrensklassen. Die in dieser Arbeit eingesetzten Modelle – Random Forest und Gradient Boosting (Abschnitt 2.3.8 und Abschnitt 2.3.9) – beruhen stattdessen auf Entscheidungsbäumen und sind nicht biologisch motiviert.

2.3.1. Überwachtes Lernen

In dieser Arbeit kommt ausschließlich überwachtes Lernen zum Einsatz (Hastie u. a. 2009). Dabei lernt das Modell aus Beispielpaaren von Eingaben und zugehörigen, bekannten Zielwerten. Je nach Art des Zielwerts unterscheidet man zwei Aufgabentypen, die in dieser Arbeit beide vorkommen: Klassifikation, bei der eine diskrete Klasse vorhergesagt wird (etwa ob ein Fahrzeug in einer gegebenen Stunde fährt oder geparkt ist), und Regression, bei der ein kontinuierlicher Wert geschätzt wird (etwa die Abfahrts- oder Rückkehrzeit).

2.3.2. Merkmale und Feature Engineering

Bei Machine Learning ist oft die Rede von Feature Engineering, oder das umformen von Merkmalen (Géron 2022). Ein Merkmal ist beispielsweise eine Spalte in einer Comma-Separated-Value Datei (siehe Abbildung 2.1), hierbei könnte es sich um jede der Spalten handeln. Folglich ist der Zeitstempel, die Handlung, der Ort oder auch der Energiekonsum ein Merkmal bzw. Feature.

In der Regel sind die Daten in ihrer Rohform nicht direkt aussagekräftig, weswegen sie interpretiert werden müssen. Ein Zeitstempel (Beispiel: 2026-05-25 08:00:00) hat ohne Kontext keinen bestimmten Wert, daher extrahiert man durch Feature Engineering die verborgenen Informationen und macht sie für das Modell zugänglich. Der genannte Zeitstempel bspw. ist im Kontext von Mobilität:

- Ein Montag -> Werktag
- Acht Uhr -> Pendlerzeit

Ein Modell entdeckt Muster nicht von selbst, daher muss man die Informationen verwertbar machen. Tage die nicht auf einen Werktag fallen, oder eine andere Uhrzeit haben, die keine Pendlerzeit ist, kann je nach restlichem Informationsgehalt (Ort, Fahrtstrecke, Aufenthaltsdauer) zu einem jeweils anderen Ergebnis führen.

Lag-Merkmal

Ein Lag ist der Wert eines Merkmals aus einem früheren Zeitschritt (Hyndman u. a. 2021). Lags sind teilweise periodisch und sind mit Stundenwerten gleichzusetzen. Ein `Lag_1` beispielsweise ist das selbe Event, nur eine Stunde in der Vergangenheit, selbiges Schema gilt für einen `Lag_168`, dieser liegt 168 Stunden in der Vergangenheit. Es gibt sehr spezifische Werte und diese erlauben auf bestimmte Muster Rückschlüsse. Lags von 1, 2, 24 und 168, wobei 24 Stunden einen Tag und 168 Stunden sieben Tage in der Vergangenheit abbilden.

Ein Risiko, das durch Lag auftreten kann, ist die Rechnung über mehr als ein Fahrzeug hinweg. Dadurch kann ein Verhalten auf ein anderes Fahrzeug interpretiert werden und falsche zugewiesene Verhaltensmuster errechnen.

Rolling-Aggregate

Ein „Rolling Mean“, oder Rolling-Mittel, fasst ein Zeitfenster zu einer Kennzahl zusammen (Hyndman u. a. 2021). So werden beispielsweise die letzten 24 Stunden oder 7 Tage Aktivitätsanteil zusammengefasst.

Data Leakage ist ein Risiko, das bei einem Rolling Mean auftreten kann, indem es die Zukunft einbezieht oder sogar den Zielwert selbst mit einrechnet. Dadurch lernt das Modell den tatsächlich gewünschten Wert und kann diesen, fälschlicherweise, richtig wiedergeben. Eine Falschimplementierung kann dazu führen, dass die Tests übermäßig gut abschneiden, im Realfall jedoch komplett versagen.

2.3.3. Training

Wenn ein Modell trainiert wird, passt es die eigenen internen Parameter an die Trainingsdaten an, sodass Vorhersagen möglichst gut zu den gelernten Zielwerten passt (Bishop 2006). Formal wird dabei das Resultat einer Verlustfunktion minimiert, welche misst, wie weit die Vorhersage von der Wahrheit abweicht. Bei einem baumbasierten Modell werden konkret Splits gewählt für bestimmte Merkmale und Schwellen, die gewisse Zielgrößen im jeweiligen Knoten am besten trennen (siehe Abschnitt 2.3.7).

2.3.4. Generalisierung

Das Prinzip der Generalisierung ist es, ein Modell so zu trainieren, dass es die Muster der Daten erkennt und deren Berechnung erlernt (Hastie u. a. 2009). Das

bedeutet, dass das Modell auch mit neuen Daten – die ungesehene Inhalte verwenden – umgehen kann, die nah am gelernten Schema liegen. Tabelle 2.2 fasst zusammen, wie sich Unter-, gute und Überanpassung anhand von Trainings- und Testfehler unterscheiden lassen.

Overfitting

Bei einem überangepassten Modell sind Trainingsfehler niedrig und Testfehler hoch. Kurzum bedeutet das, dass das Modell die Daten zu gut kennt und diese quasi auswendig weiß, bei neuen Daten jedoch oft und stark abweicht.

Underfitting

Ein Modell das unterangepasst ist, schneidet weder beim Training, noch beim Test gut ab. Hier ist das Modell zu simpel bzw. seine Kapazität zu gering, um das zugrunde liegende Muster zu erfassen. Fehler bleiben dadurch bei beiden Datensätzen hoch.

Anpassung	Trainingsfehler	Testfehler	Charakteristik
Underfitting	hoch	hoch	Modell zu simpel; das zugrunde liegende Muster wird nicht erfasst.
Gute Anpassung	niedrig	niedrig	Kleine Generalisierungslücke; die Muster werden auf neue Daten übertragen.
Overfitting	sehr niedrig	hoch	Große Generalisierungslücke; Trainingsdaten werden inklusive Rauschen auswendig gelernt.

Tabelle 2.2.: Charakterisierung von Anpassungen anhand von Fehlerwerten Géron 2022.

2.3.5. Validierung

Durch die Validierung ist es möglich der Genauigkeit des Modells einen numerischen Wert zuzuweisen, was funktioniert, indem man das Modell Daten bewerten lässt, die bisher nicht bekannt waren.

$$\text{CV}(\hat{f}) = \frac{1}{N} \sum_{i=1}^N L(y_i, \hat{f}^{-\kappa(i)}(x_i)) \quad (2.1)$$

Die Gleichung (2.1) beschreibt die Genauigkeit eines Modells auf einer bestimmten Menge Daten. Hierfür wird ein Datensatz in K gleichgroße Mengen unterteilt – auch *Folds* genannt – gefolgt von K trainings. Da K *Folds* existieren, wird das Modell einmal mit jedem *Fold* getestet und hat zur Grundlage die restlichen *Folds*.

2.3.6. Bewertungsmetriken

Die Güte des Modells wird durch die Bewertungsmetriken bestimmt, die sich je nach Art der Zielgröße unterscheiden. Bei Klassifikationsproblemen werden Metriken wie Genauigkeit, Präzision, Recall und F1-Score verwendet, bei Regressionsproblemen hingegen Metriken wie mittlerer absoluter Fehler (MAE), mittlerer quadratischer Fehler (MSE) und R^2 . Abhängig von der Art des Problems und den Zielen der Analyse werden die entsprechenden Metriken ausgewählt, um die Leistung des Modells entsprechend zu bewerten.

2.3.7. Entscheidungsbäume

Sie bilden einen Teil des maschinellen Lernens, sind jedoch grundlegend verschieden zu den menschlich inspirierten neuronalen Netzen. Entscheidungsbäume imitieren ein regelbasiertes und hierarchisches Vorgehen. Getrieben von Daten entscheidet deren Label-Vollständigkeit, ob ein Baum supervised oder unsupervised trainiert wird. So sorgen Daten die gar nicht gelabelt sind dafür, dass ein Baum unsupervised trainiert wird. Das bedeutet, dass der Baum selbstständig Muster in den Daten erkennt und diese in einer Hierarchie abbildet. Bei einem (semi-)supervised Baum hingegen, werden die Daten entweder vollständig oder teilweise mit Labels versehen und der Baum lernt anhand dieser Labels die Abbildung auf die Zielwerte. Unabhängig davon entscheidet der Typ der Zielvariable, ob ein Baum regressiv oder klassifikatorisch trainiert wird.

Gini Index

Die allgemeine Form der Gini-Unreinheit für einen Knoten mit C Klassen und den Klassenanteilen p_i lautet (Breiman u. a. 1984):

$$G = 1 - \sum_{i=1}^C p_i^2 \quad (2.2)$$

Für den binären Fall mit zwei Klassen ($p_1 = p$, $p_0 = 1 - p$) vereinfacht sich Gleichung (2.2) zu (Breiman u. a. 1984):

$$G = 1 - (p^2 + (1 - p)^2) = 2p(1 - p) \quad (2.3)$$

Hier spricht man von einer Unreinheit: einer Metrik, die ausdrückt, mit welcher Wahrscheinlichkeit ein Wert einer falschen Klasse zugeordnet würde, wenn er anhand der Klassenverteilung im Knoten ein zufälliges Label erhielte. Die gewichtete Unreinheit eines Splits ergibt sich aus den Unreinheiten der beiden Kindknoten (Breiman u. a. 1984):

$$G_{\text{split}} = \frac{n_{\text{links}}}{n} G_{\text{links}} + \frac{n_{\text{rechts}}}{n} G_{\text{rechts}} \quad (2.4)$$

In Gleichung (2.4) zeigt n die Elemente im Elternknoten und G die Unreinheit des jeweiligen Knoten an. Der Rest funktioniert analog, anhand der vorausgegangenen Formeln. Mit der Split-Formel lassen sich mehrere Iterationen pro Knoten vornehmen, wovon dann der reinste Split verwendet wird, um im Baum eine Rekursionsebene tiefer zu schreiten. Insgesamt funktioniert dieser Split $n - 1$ mal.

Abbildung 2.4 zeigt einen beispielhaften Entscheidungsbaum mit den je Knoten berechneten Gini-Werten, Stichprobengrößen und Klassenverteilungen.




Abbildung 2.4.: Entscheidungsbaum mit Aufteilungskriterien (nach Schilli 2017).

Bagging und Boosting

Das Baggingverfahren sorgt dafür, dass die Bäume von einer in der realen Trainingsmenge existierenden Untermenge Lernen. Es werden aus der Ursprungsmenge




Abbildung 2.5.: Bagging: Aus den Trainingsdaten werden N Bootstrap-Stichproben gezogen, auf denen jeweils ein Baum trainiert wird; deren Vorhersagen werden zu einem Ensemble aggregiert (ResearchGate 2022).

N Stichproben gezogen, auf denen jeweils ein Classifier/Regressor trainiert wird (Abbildung 2.5, ResearchGate 2022). Für jede Stichprobe wird ein Modell trainiert, das anschließend zu einem Ensemble aggregiert wird. Dadurch, dass alle Bäume auf unterschiedlichen Stichproben trainiert werden, wird die Varianz des Modells reduziert und die Vorhersagegenauigkeit verbessert. Bagging ist besonders effektiv bei Modellen, die zu Überanpassung neigen.

Boosting sorgt dafür, dass die Bäume auf den Residualfehlern der vorherigen Iteration trainiert werden (Abbildung 2.6, ResearchGate 2021). Dadurch wird die Vorhersagegenauigkeit des Modells verbessert. Im Gegensatz zu Bagging, bei dem die Bäume unabhängig voneinander trainiert werden, werden beim Boosting die Bäume sequentiell trainiert, wobei jeder Baum auf den Fehler des vorherigen Baums aufbaut. Dies ermöglicht es dem Modell, sich auf schwierige Beispiele zu konzentrieren und die Gesamtleistung zu verbessern. Im Kern besteht Boosting darin, schwache Lernalgorithmen zu kombinieren, um einen starken Lernalgorithmus durch gewichtete Aggregation zu erstellen. Boosting ist besonders effektiv bei Modellen, die zu Unteranpassung neigen.

In der nachfolgenden Sektion werden der Random Forest Abschnitt 2.3.8 und die Light Gradient Boosting Machine Abschnitt 2.3.9 vorgestellt, die auf den zuvor beschriebenen Prinzipien von Entscheidungsbäumen, Bagging und Boosting basieren. Abbildung 2.7 veranschaulicht den zentralen Unterschied im Baumwachstum: LightGBM wächst *leaf-wise* so, dass Knoten mit dem größten Fehlerbeitrag aufgeteilt werden, während klassische Verfahren, wie der Random Forest, *level-wise* wachsen.




Abbildung 2.6.: Boosting: Die Modelle werden nacheinander trainiert, wobei jedes folgende Modell auf den Fehlern des vorherigen Modells basiert (ResearchGate 2021).




Abbildung 2.7.: Baumwachstum in Ensemble-Verfahren (ScienceDirect 2026).

2.3.8. Random Forest

Ein Typ der Entscheidungsbaum-Modelle ist der Random Forest. Dieser besteht im Normalfall aus mehreren Entscheidungsbäumen, die, bei Bagging, jeweils auf einem zufälligen Teil der Trainingsdaten trainiert werden (Abbildung 2.5). Die Vorhersagen einzelner Bäume werden anschließend zu einem Ensemble aggregiert, um die Gesamtvorhersage zu verbessern. Random Forest ist besonders effektiv bei Modellen, die zu Überanpassung neigen, da die Aggregation der Vorhersagen die Varianz reduziert und die Generalisierungsfähigkeit verbessert.

2.3.9. Light Gradient Boosting Machine

Die Light Gradient Boosting Machine (LightGBM) ist ein Gradient-Boosting-Mechanismus, der auf Entscheidungsbäumen basiert, welche auf den Residualfehlern der vorherigen Iteration trainiert werden. In dieser Arbeit wird LightGBM ohne Bagging verwendet, aber mit Boosting, um die Vorhersagegenauigkeit zu verbessern. LightGBM ist besonders effektiv bei Modellen, die zu Unteranpassung neigen, da es die Vorhersagegenauigkeit verbessert, indem es sich auf die Fehler der vorherigen Iteration konzentriert und *leaf-wise* (Abbildung 2.7) wächst.

2.3.10. Unsicherheit und Quantilsregression

Es gibt zwei Arten der Unsicherheit, die man bei Prognosen betrachten kann:

- **Aleatorische Unsicherheit:** Hier wird der Zufall im Prozess selbst betrachtet, der nicht durch weitere oder bessere Daten reduziert werden kann. Beispielsweise kann das Wetter nicht deterministisch vorhergesagt werden, da es intrinsisch zufällig ist. Unter anderem nennt man diese auch Datenunsicherheit.
- **Epistemische Unsicherheit:** Hier wird die Unsicherheit betrachtet, die durch unvollständige Informationen oder unzureichendes Wissen über den Prozess entsteht. Diese Unsicherheit kann durch zusätzliche Daten oder bessere Modelle reduziert werden. Unter anderem nennt man diese auch Modellunsicherheit.

Eine Punktprognose ist für eine Unsicherheit nicht ausreichend, da sie nur einen Wert liefert und keine Informationen über die Streuung oder die Verteilung liefert. Während die klassische Regression den bedingten Mittelwert schätzt, sagt die Quantilsregression gezielt einzelne Quantile Q_τ der Zielverteilung vorher – im Normalfall das 10., 50. und 90. Perzentil (Koenker u. a. 1978). Zur Erreichung wird der asymmetrische Pinball-Verlust minimiert:

$$\rho_{\tau}(y - \hat{y}) = \max(\tau(y - \hat{y}), (\tau - 1)(y - \hat{y})) \quad (2.5)$$

Die Formel 2.5 ist definiert durch:

- y ist der tatsächlich beobachtete Wert
- $\hat{y}$ ist der vorhergesagte Wert
- τ ist das Quantil, das geschätzt werden soll, z. B. 0,1, 0,5, 0,9
- ρ_{τ} ist Strafe oder der Pinball-Verlust, der die Abweichung zwischen dem beobachteten Wert und dem vorhergesagten Quantil misst




Abbildung 2.8.: (a) Heteroskedastisches Prognoseband: Median (P50) und 80 %-Intervall (P10–P90), dessen Breite mit der Streuung wächst. (b) ρ_{τ} für $\tau = 0,1/0,5/0,9$; die Asymmetrie schiebt die Schätzung an das jeweilige Quantil (Koenker u. a. 1978).

Beim Pinball-Verlust werden Unter- und Überschätzung je nach τ unterschiedlich gewichtet. Das Intervall zwischen $Q_{0,1}$ und $Q_{0,9}$ bildet somit ein 80 %-Prognoseband (Abbildung 2.8). Quantile werden in dieser Arbeit auf drei Wegen erzeugt: direkt per Pinball-Verlust im LightGBM-Forecaster, über die Streuung der Bäume im Random Forest (Meinshausen 2006) sowie über die Pfad-Streuung des Monte-Carlo-Rollouts.

2.3.11. Long Short-Term Memory

Das LSTM ist ein rekurrentes neuronales Netz (RNN), mit einem Zellzustand und drei Gattern (Forget, Input, Output), die den Zustand der Zelle beeinflussen. Es ist dazu entwickelt, Langzeitabhängigkeiten in Sequenzen zu lernen und ist besonders geeignet für Zeitreihenprognosen. Durch die Gatter kann das LSTM entscheiden, welche Informationen beibehalten werden und welche verworfen werden, wodurch

es in der Lage ist, relevante Muster über längere Zeiträume hinweg zu erfassen. Das LSTM umgeht das Vanishing-Gradient-Problem, das bei traditionellen RNNs auftritt, indem es den Zellzustand über viele Zeitschritte hinweg beibehält und so die Weitergabe von Informationen über lange Sequenzen ermöglicht.




Abbildung 2.9.: Aufbau einer LSTM-Zelle: Der Zellzustand C_t wird durch Forget-, Input- und Output-Gate gesteuert, die per σ - und $\tanh$ -Aktivierung festlegen, was aus dem Gedächtnis verworfen, neu geschrieben und ausgelesen wird (dida 2026).

Die Abbildung 2.9 stellt den Aufbau einer LSTM-Zelle dar, die aus dem Zellzustand C_t , drei Gattern (Forget, Input, Output) und den Aktivierungsfunktionen σ und $\tanh$ besteht. C_t , der Zellzustand, ist für die Speicherung von Informationen verantwortlich, während die Gatter bestimmen, welche Informationen beibehalten, verworfen oder neu geschrieben werden. Die Aktivierungsfunktionen σ und $\tanh$ steuern, wie die Informationen im Zellzustand verarbeitet werden und ermöglichen es dem LSTM auf diese Weise, relevante Muster in den Eingabesequenzen zu erkennen und somit Abhängigkeiten über längere Zeiträume zu erkennen. Zeitreihenprognosen, Sprachverarbeitung und Anomalieerkennung sind typische Aufgaben, bei denen LSTMs erfolgreich eingesetzt werden, da sie durch ihr Gedächtnis in der Lage sind, komplexe zeitliche Abhängigkeiten zu modellieren und Vorhersagen auf Basis historischer Daten zu treffen.

2.4. Stand der Forschung

Die Forschung zur Prognose individueller Fahrzeugnutzung lässt sich grob in mehrere Sektionen gliedern, die sich in Zielgröße, Methodik und Datengrundlage unterscheiden. Tabelle 2.3 fasst diese Sektionen als Übersicht zusammen. Jeder dieser Sektionen

beinhaltet Arbeiten, die zum Teil entweder relevant für diese Arbeit, oder zu Ihrer Eingrenzung dient. Die folgenden Unterabschnitte vertiefen die Sektionen jeweils und arbeiten am Ende die für diese Arbeit zentrale Forschungslücke heraus.

Tabelle 2.3.: Zentrale Forschungssektionen im Umfeld der individuellen Fahrzeugnutzungsprognose.

Forschungsstrang	Typische Methoden	Datengrundlage	Offene Punkte
Mobilitäts- und Nutzungsforecast	Statistische Modelle (ARIMA), Random Forest, neuronale Netze (LSTM)	Reale Telematik- und Bewegungsdaten	Generalisierung über Fahrzeuge und Quellen hinweg
Driving-/Parking-Klassifikation	Random Forest, SVM, Gradient Boosting	EV-Flottendaten, stündliche Profile	Einfluss der Datenqualität auf die Klassifikationsgüte
EV-Last- und Ladeprognose	Gradient Boosting, Deep Learning	Synthetische Daten (z. B. emobpy), reale EV-Daten	Vergleichbarkeit synthetischer und realer Datengrundlagen
Unsicherheits- und Quantilsprognose	Quantilsregression, Quantile-Random-Forest	Heterogene Mobilitätsdaten	Kalibrierung individueller Vorhersageintervalle (P10/P90)

2.4.1. Verwandte Arbeiten

Um zu verdeutlichen, womit sich diese Arbeit im wesentlichen auseinandersetzt, werden im Folgenden verwandte Arbeiten vorgestellt und voneinander abgegrenzt. Die Auswahl der Arbeiten orientiert sich an den in Tabelle 2.3 dargestellten Forschungssträngen. Dabei werden sowohl die Zielsetzung, als auch die Methodik der jeweiligen Arbeiten betrachtet, um die Unterschiede und Gemeinsamkeiten herauszuarbeiten.

Mobilitäts- und Nutzungsforecasts


Klassische Zeitreihenmodelle wie ARIMA, aber auch moderne Ansätze wie Random Forest und neuronale Netze, insbesondere LSTM sind in Verwendung, um für Mobilitätsverhalten Prognosen zu erstellen. Die Daten bestehen zum Großteil aus realen Telematik- und Bewegungsdaten, die eine hohe Granularität aufweisen. Ein zentrales

Ziel hierbei ist die Generalisierung über eins oder mehrere Fahrzeuge hinweg, um Vorhersagen für zukünftiges Fahrverhalten treffen zu können. Die Arbeiten haben den Zweck, die Genauigkeit der Vorhersagen zu maximieren und gleichzeitig die Interpretierbarkeit der Modelle zu gewährleisten.


Eine Studie beispielsweise befasst sich mit der Vorhersage von Fahrverhalten auf Grund von temperaturbedingter Batterieeffizienz – denn besonders niedrige Temperaturen können die Effizienz der Batterien erheblich beeinflussen (Lindroth u. a. 2024). Es werden Online-Lernmodelle verwendet um die Abfahrtszeit und die Distanz für den ersten Trip des Tages vorherzusagen. Abbildung 2.10 zeigt die zugrunde liegenden Verteilungen von Fahrdistanz und Abfahrtszeit, aufgeschlüsselt nach Wochentag. Es ist gut zu erkennen, dass die Fahrdistanz, unabhängig vom Wochentag, eine sehr ähnliche Verteilung aufweist, während die Abfahrtszeit stark vom Wochentag abhängt. Eine weitere Studie entwickelt ein LSTM-Modell mit raum-zeitlichen Bewertungsmechanismus, das die individuelle Fahrzeugnutzung vorhersagt. Reiseziele, aktuelle Fahrtdaten (Echtzeit-Bewegungen) und historische Bewegungsmuster werden hierbei als Datengrundlage verwendet (others 2025). Die Ergebnisse zeigen, dass das Modell im Vergleich zu spezifischen Random Forest, Distant Neighboring Dependencies, Location Semantics and Location Importance -LSTM und Intersection Transfer Preference and Current Movement Mode um ca. 10-15% übertrifft.

Driving-/Parking-Klassifikation

Die Identifikation von Fahr- und Parkzuständen ist ein zentraler Aspekt der individuellen Fahrzeugnutzungsprognose, daher ist es wichtig diese beiden Klassen zuverlässig zu unterscheiden. In der Literatur werden hierfür unterschiedliche Methoden eingesetzt. Eine Studie versucht gezielt Fahrer in bestimmte Klassen zu unterteilen, um deren Fahrverhalten besser zu verstehen (Kumar u. a. 2023). In der Studie werden IoT und Machine Learning verwendet, um Fahrverhalten anhand von OBD-II-Daten (bspw. Geschwindigkeit, Motordrehzahl, Bremsmuster) zu analysieren und das ohne zusätzliche Sensoren. Mithilfe von Support Vector Machines, AdaBoost und Random Forest werden die Fahrer in zehn Klassen unterteilt, die sich in Kraftstoffverbrauch, Lenkstabilität, Geschwindigkeitsstabilität und Bremsverhalten unterscheiden. Eine weitere Studie untersucht die Klassifikation von Fahr- und Parkzuständen, um das Verhalten präziser zu verstehen und die Genauigkeit der Vorhersagen zu verbessern (Su u. a. 2025). Die Methodik beinhaltet ein Clustering per DBSCAN, welches häufig besuchte Orte identifiziert und eine Ableitung von Gebäudekategorien vornimmt.



(a) Driving distance



(b) Departure time

Abbildung 2.10.: Verteilung der Fahrtdistanz (a) und der Abfahrtszeit des ersten Tagestrips (b) nach Wochentag (Lindroth u. a. 2024).


EV-Last- und Ladeprognose

Im Bereich der EV-Last- und Ladeprognose werden vielfältig Methoden angewandt, um die Ladebedarfe und Lastprofile von Elektrofahrzeugen zu prognostizieren. Eine Studie verfolgt hierbei einen probabilistischen Ansatz und quantifiziert die Unsicherheit des Ladeverhaltens mittels Modellen wie GAMLSS oder QGAM, um die Ladebedarfe als vollständige Prognoseintervalle statt als reine Punktwerte vorherzusagen (Amara-Ouali u. a. 2025). Eine weitere Studie entwickelt ein multivariates long short-term memory (LSTM) Modell mit einem Attention-Mechanismus, um den Ladebedarf in 15-Minuten-Intervallen vorherzusagen (Sanami u. a. 2025). Des Weiteren erhält das Modell zusätzlich Informationen über das Wetter, Wochentag, Monat und Feiertage. Der Monat wirkt sich nicht nur auf die Durchschnittliche Temperatur aus, sondern auch auf die Ladeanfragen der Nutzer, wie man in Abbildung 2.11a sieht. Die Abbildung 2.11b ist im Bezug auf die Ladeanfragen pro Monat nicht Aussagekräftig, jedoch zeigt sie, dass die Ladeanfragen sehr stark von Uhrzeiten abhängig sind. Man erkennt einen kleinen Anstieg der Ladeanfragen ab 5 Uhr, der sich bis 12 Uhr fortsetzt, bevor die Anfragen abflachen und Nachmittags wieder abnehmen.


Der Bereich für EV-Last- und Ladeprognose ist gut erforscht und liefert ein solides Fundament auf dem diese Arbeit aufbaut. Die Methoden und Modelle, die in diesen Arbeiten verwendet werden, sind relevant für die Vorhersage von Ladebedarfen und Ladeanfragen, insbesondere im Hinblick auf die Unsicherheitsquantifizierung und äußere Einflussfaktoren wie Wetter, Wochentag und Feiertage. Die Ergebnisse dieser Studien zeigen, dass die Berücksichtigung von Unsicherheiten und externen Faktoren die Genauigkeit der Vorhersagen erheblich verbessern kann.

Unsicherheits- und Quantilsprognose

Die Studie Amara-Ouali u. a. 2025 ist auch im Bereich der Unsicherheitsprognose relevant, da sie die Unsicherheit des Ladeverhaltens von Elektrofahrzeugen quantifiziert. Durch die Verwendung von probabilistischen Modellen wie GAMLSS oder QGAM werden Prognoseintervalle anstelle von Punktwerten erstellt, was eine umfassendere Darstellung der Unsicherheit ermöglicht. Eine weitere Studie (Ali u. a. 2024) befasst sich mit der Quantilsregression und deren Anwendung in der Vorhersage, gekoppelt mit einem Multi-Quantile Temporal Convolutional Network (MQ-TCN). Das Modell erzielte einen 93,62% hohen Intervallabdeckungswahrscheinlichkeit Score (PICP), der bis zu 96,88% steigt, mit nur zwei Wochen Trainingsdaten. Die Studie zeigt, dass die Quantilsregression in Kombination mit einem gut trainierten und konfigurierten neuronalen Netzwerk eine effektive Methode zur Vorhersage von Unsicherheiten in



(a) Durchschnittliche Ladeanfragen je Tageszeit, aufgeschlüsselt nach Monat.



(b) Ladeanfragen im Jahresverlauf, aufgeschlüsselt nach Wochentag.

Abbildung 2.11.: Zeitliche Muster der Ladeanfragen im verwendeten Datensatz (Sana-mi u. a. 2025).

Mobilitätsdaten darstellt. Die Ergebnisse dieser Studien sind besonders relevant für die vorliegende Arbeit, da sie die Bedeutung der Quantilsregression und der Unsicherheitsprognose in der individuellen Fahrzeugnutzungsprognose unterstreichen.

Mobilitäts- und Nutzungsforecast

Ein zentraler Befund dieser Sektion betrifft die Heterogenität individuellen Fahrverhaltens. Ji u. a. (2023) werten über vier Millionen Fahrten von 3743 privaten Fahrzeugführern in sechs US-Metropolregionen aus und zeigen, dass sich die Fahrer in fünf deutlich verschiedene Typen gliedern lassen (Tabelle 2.4), die sich vor allem in ihrer Pendelregelmäßigkeit und im Anteil nicht-arbeitsbezogener Fahrten unterscheiden. Diese Heterogenität erklärt, warum ein einzelnes, übergreifendes Modell dem Individualverkehr nur begrenzt gerecht wird, und motiviert eine individuelle bzw. quellenspezifische Modellierung.

Fahrertyp	Charakterisierung
Homebodies	Wenigfahrer, die nur kurz und selten das Haus verlassen; geringe Mobilität.
Gig Drivers	Fahrer mit hohem, auftragsgetriebenem Fahraufkommen (z. B. Liefer- und Fahrdienste) ohne festen Arbeitsort.
Movers	Individuen mit breit gestreutem Fahrverhalten und vielen wechselnden Zielen, ohne klares Muster.
Typical Drivers	Durchschnittsfahrer mit einer Mischung aus Arbeits- und Freizeitfahrten und mittlerer Regelmäßigkeit.
Work-focused Commuters	Berufspendler mit stark regelmäßigem Pendelmuster, wenig nicht-arbeitsbezogenen Fahrten und hoher Vorhersagbarkeit.

Tabelle 2.4.: Fünf Fahrertypen des Individualverkehrs nach Ji u. a. (2023).

3. Methodik

Das Ziel der Methodik ist es, die zuvor genannten Forschungsfragen in Abschnitt 1.4 zu beantworten. Um dies zu erreichen, werden in Abschnitt 3.2, Abbildung 3.2 die methodischen Schritte beschrieben, die dafür durchgeführt werden.

Datenquellen Die Varietät und Qualität der Datenquellen ist ein entscheidender Faktor für die Leistungsfähigkeit von Machine-Learning-Modellen. In dieser Arbeit werden Datenquellen verwendet, die unterschiedliche Aspekte des Problems abbilden, wovon jede auf ihre Eignung hin untersucht und in ein einheitliches Schema transformiert wird, um ein durchgehendes Feature-Set zu gewährleisten. Die Datenquellen werden in Abschnitt 3.3 detailliert beschrieben, einschließlich ihrer Herkunft, Struktur und der Art der enthaltenen Informationen. Die Auswahl der Datenquellen (ersichtlich in Abbildung 3.2) basiert auf ihrer Relevanz für die Forschungsfragen und ihrer Fähigkeit, ein möglichst breites Spektrum an Mobilitätsfragen abzudecken.

Modellfamilien Auf Grund der Studienlage und der darin stark repräsentierten Modellfamilien werden in dieser Arbeit drei verschiedene Modelle verwendet, die jeweils unterschiedliche Eigenschaften aufweisen. Die Modelle sind Random Forest, LightGBM und LSTM – welche in Abschnitt 2.3.8, Abschnitt 2.3.9 und Abschnitt 2.3.11 aufbereitet sind.

3.1. Forschungsdesign

Die Arbeit folgt einem quantitativ-experimentellen Forschungsdesign, das auf der Analyse von Daten und der Anwendung von Machine-Learning-Methoden basiert. Das Ziel ist es, die Forschungsfragen durch die systematische Gegenüberstellung von unterschiedlichen Datenquellen und Modellen zu beantworten. Da der Kern der Thesis die Erforschung eines Verfahrens ist, um die Prognosegüte von Modellen zu ermitteln, umfasst die Methodik ein kontrolliertes Experiment, die Evaluierung der

Modelle und die Durchführung einer Ablationsstudie mit numerischen Metriken und Prognosequantilen, um die Leistungsfähigkeit der Modelle zu bewerten.




Abbildung 3.1.: Variablenstruktur des Forschungsdesigns: zwei veränderliche unabhängige Variablen (Daten, Algorithmus) und eine abhängige Variable (Prognosegüte). Konstante Hyperparameter und Trainingsprotokolle wirken als Kontrollvariablen.

Die unabhängigen Variablen in der Experimentreihe sind die verschiedenen Datensätze, die jeweils unterschiedliche Informationen enthalten, und die unterschiedlichen Machine-Learning-Algorithmen. Die Hyperparameter werden je Modell einmalig festgelegt und während der Isolationsexperimente konstant gehalten; dadurch wirken sie, wie das Feature-Set und Trainingsprotokoll, als Kontrollvariablen (Abbildung 3.1). Die abhängige Variable ist die Prognosegüte, da diese von den unabhängigen Variablen beeinflusst wird. Für die Ablation werden die gelernten Modelle per Algorithmus- und Datenisolation untersucht, um die jeweiligen Effekte auf die Vorhersagegenauigkeit zu bestimmen. Die Ergebnisse werden statistisch analysiert, um die Qualität der Modelle auf Grund ihrer Datenbasis und ihres Algorithmus zu bewerten. Im Zuge dieses Aufbaus können folgende Hypothesen aufgestellt werden:

3.2. Untersuchungsablauf

Die Methodik umfasst die Auswahl und Implementierung von Datenaufbereitung und Machine-Learning-Modellen, die Gegenüberstellung der Modelle, sowie die Durchführung von Ablationsexperimenten, um die besten Modelle zu identifizieren. Die

Tabelle 3.1.: Hypothesen zu den Forschungsfragen.

Nr.	Hypothese der Forschungsfrage
Mobilitätsprognose	
FF1	Durch die Kombination eines ausreichend komplexen Modells mit hochqualitativen Trainingsdaten kann das individuelle Mobilitätsverhalten zuverlässig vorhergesagt werden.
FF1.1	Der Vergleich verschiedener Verfahren des maschinellen Lernens zeigt unterschiedliche Vorhersagegenauigkeiten.
FF1.1.1	Die Datenqualität und -quelle haben einen erheblichen Einfluss auf die Prognosegüte, unabhängig vom gewählten Algorithmus.
FF1.2	Die wichtigsten Merkmale, die das individuelle Mobilitätsverhalten beeinflussen, sind u.a. der Tageszeitpunkt, die Wochentagsstruktur und die historischen Fahrten.
Mobilitätsdaten	
FF2	Anforderungen, die sich ergeben, sind u.a. Anspruch an Form, Qualität, Relevanz und Verwendbarkeit der Daten.
FF2.1	Aufbereitung wirkt sich im Optimalfall nicht auf die Nutzbarkeit der Daten aus; Fehlerhafte Daten können optional für Robustheit beibehalten werden.
FF2.2	Die Qualität der Daten lässt sich oberflächlich durch ihre Kohärenz, Vollständigkeit und Reichhaltigkeit bewerten. Tiefergehend lässt sich die Qualität der Daten anhand der Prognosequalität der Modelle interpretieren.

Methodik ist in Abbildung 3.2 schematisch dargestellt. Der Arbeitsfluss beginnt mit der Auswahl und Aufbereitung der Daten – in diesem Fall fünf verschiedene Datenquellen – welche in ein einheitliches Schema transformiert werden. Als nächstes werden die Daten auf ihre Qualität hin bewertet und relevante Features extrahiert. Anschließend werden die Daten in Modelle eingespeist, die unterschiedliche Aufgaben erledigen: Klassifikator und Zeitreihenprognose. Die Modelle werden dann in einem experimentellen Design evaluiert, das sowohl die Isolation von Daten- und Algorithmen-Effekten als auch eine Ablationsstudie umfasst. Das Isolieren der Daten- und Algorithmen-Effekte ist ein wichtiger Aspekt der Methode, um sicherstellen zu können, dass die Ergebnisse auf die jeweiligen Einflussfaktoren zurückgeführt werden können. Abschließend werden die Ergebnisse bewertet und die Forschungsfragen beantwortet.

Die Arbeit lässt sich in drei große Teile gliedern:

- **Datenaufbereitung:** Das Erkundschaften der Datenlandschaft, die Transformation der Daten in ein geeignetes Format und die Auswahl relevanter Features.
- **Machine Learning:** Die Auswahl und Implementierung verschiedener Machine-Learning-Modelle auf Grund ihrer unterschiedlichen Eigenschaften (leaf- und level-wise Wachstum, Bagging und Boosting, modellierte zeitliche Abhängigkeiten).
- **Ablationsexperimente:** Im Rahmen einer Ablationstudie werden verschiedene Modelle hinsichtlich ihrer Wertigkeit (in diesem Fall: Vorhersagegenauigkeit, Robustheit, Zuverlässigkeit) miteinander verglichen, um die besten Modelle zu identifizieren.

3.3. Datengrundlage und Quellen

Da die Daten einen großen Einfluss auf die Leistungsfähigkeit der Modelle haben, werden in dieser Arbeit fünf verschiedene Datenquellen verwendet, die unterschiedliche Aspekte des Problems abdecken. Jede Datenquelle wird auf ihre Eignung hin untersucht und in ein einheitliches Schema transformiert, sodass ein durchgehendes Feature-Set gewährleistet ist. Die Datenquellen werden hinsichtlich ihrer Herkunft, Struktur, Art der enthaltenen Informationen und Zweck ihres Gebrauchs beschrieben. Die Auswahl ist auf ihre Relevanz für die Forschungsfragen und ihr Potenzial, vorliegende Mobilitätsfragen zu beantworten, begründet. Die Datenquellen sind in Tabelle 3.2 zusammengefasst.




Abbildung 3.2.: Schematischer Workflow der Methodik: von den fünf Datenquellen über den geteilten Feature-Kern und die beiden Aufgabenmodelle bis zum Experimentaldesign und der Bewertung.

Tabelle 3.2.: Übersicht der fünf Datenquellen und ihrer identifizierenden Eigenschaften.

Quelle	Art	Träger	Umfang
emobpy	synthetisch	Fahrzeug	200 Fahrzeuge, 1 Jahr
real_world_ev	real	Fahrzeug	1 Fahrzeug, 1 Jahr
ved	real	Fahrzeug	383 Fahrzeuge, 1 Jahr
routine	synthetisch	Person	1 Person, dynamisch
yjmob100k	real	Person	25.000 Personen, 75 Tage

emobpy ist ein Open-Source-Python-Tool, das vom DIW Berlin (Deutsches Institut für Wirtschaftsforschung) entwickelt wurde, um synthetische Mobilitätsdaten zu generieren (Gaete-Morales u. a. 2021). Die Daten werden auf Basis von realen Mobilitätsstatistiken und physikalischen Eigenschaften von Elektrofahrzeugen erzeugt. Für die Illustration des Tools wurde ein Profil von 200 Fahrzeugen über ein Jahr in Deutschland simuliert. **emobpy** liefert ein `in_use`-Flag, weswegen die Identifikation des Fahrverhaltens direkt aus den Daten abgeleitet werden kann. Die Aktivitätsrate liegt im Median bei 9,66 %.

real_world_ev ist ein Datensatz, der über ein Jahr hinweg Fahrdaten eines einzelnen Elektrofahrzeugs sammelt, um dessen Batterieverhalten besser verstehen zu können (Pozzato u. a. 2023). Die Daten liegen im `.mat`-Format vor, weswegen diese in Python eingelesen, in ein einheitliches Schema transformiert und für die Modellierung in eine `.csv`-Datei exportiert werden. Da es keine Flag wie `in_use` gibt, die anzeigt, ob das Fahrzeug tatsächlich in Benutzung ist, wird die Aktivität über eine Stromschwelle von 5 A (Fahren) sowie den Ladeprozess bestimmt; **driving** umfasst bei dieser Quelle also Fahren *und* Laden. Da der Datensatz nur ein Fahrzeug umfasst, liegt dessen Aktivitätsrate bei 5,54 %.

ved (Vehicle Energy Dataset) ist ein Datensatz, der durch die Universität Michigan, das Argonne National Lab und das Idaho National Lab bereitgestellt wird (Oh u. a. 2022). Die Daten stammen von 383 Fahrzeugen, welche in Ann Arbor, Michigan, USA über ein Jahr hinweg Fahrdaten gesammelt haben. Die OBD-II-Signale werden hochfrequent *während der Fahrt* protokolliert; für Parkzeiten liegen keine Messpunkte vor, sodass sich die Fahraktivität unmittelbar aus der Existenz eines Eintrags ableiten lässt und ein zusätzlicher Aktivitätsfilter entfällt. Der Datensatz hebt sich mit seiner stark abweichenden Aktivitätsrate ab; der Median liegt bei 0,99 %, die Spanne jedoch

bei 0–100 %. Diese ergibt sich daraus, dass manche Fahrzeuge keine aktiven Stunden aufzeichnen, andere nur einen einzelnen Tag, der ausschließlich aus Fahrten besteht.

routine ist ein stark regelbasierter Algorithmus, um synthetische Daten zu generieren. **routine** wurde im Verlauf dieser Arbeit entwickelt, um eine an deutsche Arbeitsalltage angelehnte Alternative zur Hand zu haben. Die Tagesabläufe richten sich stark nach dem üblichen Muster:

- **Arbeit:** 3-Schicht-Modell
- **Außerordentliches:** Trips, die nicht zur Arbeit gehören. Freizeit, Einkauf, andere Aktivitäten
- **Wochenende:** Keine oder weniger Arbeit. Unregelmäßiges Fahrverhalten.
- **Sonn- und Feiertage:** Keine Arbeit, wenige Freizeitmöglichkeiten. Somit geringstes Verkehrsaufkommen

Beim **routine**-Algorithmus ist die Aktivitätsrate variabel; beim zuletzt generierten Datensatz liegt sie bei circa 25 %. Der Algorithmus erzeugt einzelne Personen, die einen nachvollziehbaren Tagesablauf verfolgen.

yjmob100k hebt sich von den anderen Datensätzen ab, da er Bewegungsdaten von Smartphones statt von Fahrzeugen selbst erfasst (Yabe u. a. 2024). Bildlich gesprochen wird ein Raster mit 500 m Kantenlänge, also 250.000 m² Fläche, auf die Karte gelegt; eine Bewegung wird nur dann erkannt, wenn eine Grenze zu einer anderen Rasterzelle überschritten wird. Da als Bewegung jeder Zellenwechsel gilt – inklusive nicht-motorisierter Wege, die in einer Großstadt (hier in Japan) häufig zu Fuß zurückgelegt werden – ergibt sich eine höhere Median-Aktivitätsrate von 35,33 % bei einer Spanne von 3,9–84,72 %. Diese Rate ist daher nicht direkt mit den fahrzeugbasierten Quellen vergleichbar.

Die Aufbereitung der Daten erfolgt in einem einheitlichen Muster – durch einen Adapter. Die enthaltenen Informationen werden auf das Wesentliche gekürzt: Fahrzeugidentifikationskennung und die Information, ob sich das Fahrzeug im Moment im geparkten oder fahrenden Zustand befindet. Datensätze, die keine konkrete Information darüber enthalten, ob ein Fahrzeug sich fortbewegt, werden durch andere Methoden identifiziert – bei **real_world_ev** wird beispielsweise die momentane Stromstärke verwendet, bei **ved** genügt die Existenz eines Eintrags, da nur Fahrten dokumentiert werden.

Die Qualität der Datensätze lässt sich durch die Prognosegüte evaluieren, denn selbst wenn der Datensatz keine Fehler aufweist und laut Überprüfung optimal wäre, bestünde die Möglichkeit, dass die Varianz über die Fahrzeuge hinweg zu groß ist und somit für Anforderungen der individuellen Mobilitätsprognose nicht ausreicht.

Da die individuelle Mobilitätsprognose für möglichst viele unterschiedliche Personen zuverlässig funktionieren soll, ist es von Vorteil, grundverschiedene Quellen zum Trainieren und Testen zu verwenden: Nur so lässt sich prüfen, ob das Verfahren über heterogene Datenbedingungen hinweg generalisiert. Die Quellen unterscheiden sich in der Art der Erhebung bzw. Erzeugung, dem Ort der Studie, der Anzahl der Subjekte, den Rahmenbedingungen und dem Erhebungszeitraum. Gerade wegen dieser starken Heterogenität (stark unterschiedliche Definition von Aktivität) sind die absoluten Aktivitätsraten der Quellen nur eingeschränkt direkt vergleichbar. Die Überführung in ein einheitliches Schema und das isolierende Experimentaldesign stellen sicher, dass Daten- und Algorithmuseffekt dennoch getrennt beurteilt werden können.

3.4. Feature Engineering

Das stündliche Driving-Raster ist die Eingangs- und Zielstruktur, aus deren Vergangenheit Merkmale abgeleitet werden. Das Driving-Raster sorgt dafür, dass die Daten in einem festen Schema aufbereitet werden, um damit in einem geregelten Muster arbeiten zu können.

Des Weiteren gehört zu den Features:

- Hour, Weekday, Is_weekend
- Lag_1, Lag_2, Lag_24, Lag_168
- Rolling_mean_24, Rolling_mean_168

3.5. Modellauswahl

3.6. Experimentaldesign

3.7. Bewertung

4. Implementierung

TODO: Einleitenden Text verfassen. Was wird in diesem Kapitel vorgestellt?

TODO: memo: kapitel = das WIE (code), nicht methodik wiederholen. bogen: anforderungen -> architektur -> tech -> umsetzung (kern: adapter, features, leakage, 5x5-cv, forecaster) -> herausforderungen.

4.1. Anforderungen

Im folgenden werden die funktionalen und nicht-funktionalen Anforderungen an das System beschrieben. Diese Anforderungen bilden die Grundlage für die Implementierung und dienen als Referenzpunkt für die Bewertung des Systems. Die Anforderungen werden Anhand von Titel, Kürzel, Kurzbeschreibung und Priorität dargestellt. Die Priorität wird in drei Stufen unterteilt: *hoch*, *mittel* und *niedrig*.

Tabelle 4.1.: Anforderungen

Titel	Kürzel	Kurzbeschreibung	Priorität
Daten			
Erhebung	R-1.0	Daten für die Erstellung von Modellen werden erfasst, auf das richtige Format überprüft und bereitgestellt.	hoch
Aufbereitung	R-1.1	Daten werden aufbereitet und in das richtige Format gebracht: Informationsgehalt und -qualität, Granularität	mittel
Speicherung	R-1.2	Daten werden dauerhaft persistiert.	niedrig
System			
Systemstart	R-2.0	Funktionalität 4	hoch
Systemüberwachung	R-2.1	Funktionalität 5	mittel
Machine Learning Modelle			
Modelltraining	R-3.0	Funktionalität 6	hoch
Modellevaluierung	R-3.1	Funktionalität 7	hoch

TODO: memo: platzhalter 'Funktionalität 4-7' ersetzen. R-2.0 systemstart = backend uvicorn hochfahren + modelle/registry laden; R-2.1 überwachung = /api/runs status & logs; R-3.0 training = train_<source>_forecaster.py; R-3.1 eval = run_cross_validation.py (5x5). ausserdem: funktional vs nicht-funktional sauber trennen – perf/robustheit/reproduzierbarkeit = nicht-funktional.

4.2. Systemarchitektur

TODO: Die Gesamtarchitektur des Systems beschreiben. Welche Komponenten gibt es und wie interagieren sie?

TODO: memo: komponentenkette: data_adapters.py (loader je quelle) -> base.py (make_features / FEATURE_COLS) -> classifier/ (driving) + forecast/ (rf, lgbm) -> forecaster_registry (name->klasse, lazy) -> backend.py (fastapi: /api/models, /forecast, /runs) -> frontend (angular, signals). persistenz: models/<source>_forecaster_<algo>.joblib + driving_<source>.joblib; runs unter predictions/<model>/<run>/forecast.csv (helper run_output_dir() in base.py). duck typing: forecaster-iface fit/predict/predict_quantiles/save/load. KEIN baseclass. -> eigenes komponentendiagramm zeichnen (stil wie fig:methodik).

4.3. Technologieauswahl

TODO: Welche Technologien, Frameworks, Programmiersprachen und Werkzeuge wurden eingesetzt und warum?

TODO: memo: python 3.13 (namespace-package, kein __init__). sklearn Random-Forest. lightgbm optional (nur bei -model lgbm importiert). pandas/numpy. h5py fuer .mat (HDF5 v7.3) -> parse_real_world_ev.py. joblib fuer persistenz. backend fastapi + uvicorn. frontend angular 17 standalone + signals. WARUM je modell begründen: RF = bagging/baseline, LGBM = boosting/leaf-wise, LSTM = rekurrent -> für ablation. warum CPU/lokal statt cloud/gpu.

4.4. Umsetzung

TODO: Zentrale Aspekte der Implementierung beschreiben. Wichtige Algorithmen, Datenstrukturen oder Designentscheidungen erläutern.

TODO: memo KERN – hier steckt die arbeit. (1) `data_adapters.py`: loader je quelle -> einheitl. schema `vehicle_id/timestamp/driving`; `VED_EPOCH + DayNum`, `yj-mob = bewegungsproxy (zellwechsel)`, `real_world_ev in_use = 5A ODER laden`. (2) `base.py` `make_features`: kalender (`hour/weekday/is_weekend`) + lag (`1/2/24/168`) + `rolling_mean (24/168)`; `FEATURE_COLS`, `TrainConfig`, `split_by_time`. (3) `LEAKAGE = base.py 65-94` -> CODE-LISTING einfügen + erklären: `groupby(vehicle_id)` kein cross-vehicle, `shift(1)` VOR dem rolling-fenster (zielwert fließt nicht ins eigene feature), zeitlicher split, dropna der NaN-lags. (4) classifier: `run_cross_validation.py = 5x5` (train-quelle x test-quelle) isolationsmatrix. (5) `forecast/`: `predict(n_days, threshold)`; P10/P90 auf 3 wegen – pinball (lgbm), baum-streuung (rf), mc-rollout. konkrete listings: `make_features`, `in_use-ableitung`, `5x5-loop`.

4.5. Herausforderungen

TODO: Welche Herausforderungen traten bei der Implementierung auf? Wie wurden sie gelöst?

TODO: memo: (1) `.mat` HDF5 v7.3 parsen mit `h5py`, relative gerätzeit -> abs. zeit per epoch-anker interpoliert, signale auf `TimeCurr-raster` (`parse_real_world_ev.py`). (2) aktivitätsdefinition je quelle unterschiedlich (fahren vs. fahren+laden vs. bewegungsproxy) -> zielgröße nicht 1:1 vergleichbar. (3) starkes klassenungleichgewicht (VED aktiv ca. 1%) -> accuracy trügt, F1/PR-AUC nötig. (4) VED degenerate fahrzeuge (0% / 100% aktiv) -> filter? (5) windows: doppelte punkt in pfad verboten -> run-dir als `T<DD-MM-YYYY>`. (6) `lightgbm` nur optional importierbar. (7) per-vehicle `groupby` gegen lag-leakage über fahzeuggrenzen. (8) CPU-only -> lange trainingszeit, –limit-flags.

5. Evaluation

TODO: Einleitenden Text verfassen. Was wird evaluiert und mit welchem Ziel?

5.1. Evaluationsdesign

TODO: Das Design der Evaluation beschreiben. Welche Metriken, Kriterien oder Hypothesen werden überprüft?

5.2. Testumgebung

TODO: Die Testumgebung beschreiben (Hardware, Software, Datensätze, Konfigurationen).

5.3. Ergebnisse

TODO: Die Ergebnisse der Evaluation präsentieren. Tabellen und Grafiken verwenden.

Tabelle 5.1.: Modell (RandomForest) im Vergleich zu naiven Baselines, In-Distribution je Datenquelle auf demselben zeitlichen Test-Split. Majority = „immer geparkt“; Persistenz-168 = gleiche Stunde der Vorwoche; Klimatologie = $P(\text{fahren} \mid \text{Wochentag, Stunde})$ aus dem Trainingsteil.

(a) PR-AUC (Zufalls-Baseline = Aktiv-Rate; höher = besser)

Datenquelle	Modell (RF)	Majority	Persistenz-168	Klimatologie
emobpy	0,267	0,096	0,105	0,172
real_world_ev	0,640	0,023	0,023	0,022
ved	0,091	0,048	0,078	0,083
routine	0,884	0,264	0,672	0,797
yjmob100k	0,683	0,382	0,478	0,489

(b) Accuracy (Accuracy-Trugschluss: Majority oft am höchsten)

Datenquelle	Modell (RF)	Majority	Persistenz-168	Klimatologie
emobpy	0,697	0,904	0,838	0,904
real_world_ev	0,983	0,977	0,956	0,977
ved	0,880	0,952	0,919	0,952
routine	0,898	0,736	0,887	0,868
yjmob100k	0,726	0,618	0,659	0,619

Tabelle 5.2.: In-Distribution-Gütemaße des Driving-Classifiers je Datenquelle (Acc. = Accuracy, ROC = ROC-AUC, PR = PR-AUC, Brier = Brier-Score, Aktiv-Rate = Anteil der Fahrstunden). Beide Algorithmen nutzen denselben Feature-Satz.

(a) RandomForest

Datenquelle	Aktiv-Rate	Acc.	F1	ROC	PR	Brier
emobpy	0,096	0,697	0,319	0,798	0,267	0,169
real_world_ev	0,023	0,983	0,681	0,884	0,640	0,020
ved	0,048	0,880	0,077	0,733	0,091	0,090
routine	0,264	0,898	0,818	0,961	0,884	0,073
yjmob100k	0,382	0,726	0,669	0,798	0,683	0,182

(b) LightGBM

Datenquelle	Aktiv-Rate	Acc.	F1	ROC	PR	Brier
emobpy	0,096	0,641	0,307	0,809	0,277	0,191
real_world_ev	0,023	0,969	0,366	0,850	0,256	0,027
ved	0,048	0,846	0,092	0,687	0,077	0,110
routine	0,264	0,880	0,783	0,954	0,873	0,090
yjmob100k	0,382	0,726	0,676	0,807	0,699	0,180

6. Diskussion

TODO: Einleitenden Text verfassen. Was wird in diesem Kapitel diskutiert?

6.1. Interpretation der Ergebnisse

TODO: Die Ergebnisse aus Kapitel 5 interpretieren. Was bedeuten die Ergebnisse im Kontext der Forschungsfragen?

6.2. Vergleich mit verwandten Arbeiten

Da sich bislang nur wenige Arbeiten mit der Erstellung von Modellen für die Prognose individuellen künftigen Mobilitätsverhaltens befasst haben, liegt keine Grundlage für einen direkten Vergleich vor, sodass hierzu keine belastbare Aussage getroffen werden kann.

Studien die sich mit individuellem Mobilitätsverhalten befassen, schauen hauptsächlich nach *State of Charge* oder *Ortsdaten*. **TODO:** Wie verhalten sich die Ergebnisse im Vergleich zu verwandten Arbeiten aus Abschnitt 2.4.1? – – verbessern

6.3. Limitationen

TODO: Welche Einschränkungen hat die Arbeit? Was konnte nicht untersucht werden? Welche Annahmen wurden getroffen? – – verbessern

- aktive datenerhebung
- realer verkehr
- parallele studien

6.4. Implikationen

TODO: Welche praktischen und theoretischen Implikationen ergeben sich aus den Ergebnissen?

7. Fazit und Ausblick

7.1. Beantwortung der Forschungsfragen

TODO: Jede Forschungsfrage aus Abschnitt 1.4 explizit beantworten.

1. **TODO:** Antwort auf Forschungsfrage 1
2. **TODO:** Antwort auf Forschungsfrage 2
3. **TODO:** Antwort auf Forschungsfrage 3

7.2. Ausblick

TODO: Welche zukünftigen Arbeiten könnten auf dieser Arbeit aufbauen? Welche offenen Fragen bleiben bestehen?

Literaturverzeichnis

- Ali, Mohammad Wazed, Asif bin Mustafa, Md. Auferul Moin Shuvo und Bernhard Sick (2024). *Location based Probabilistic Load Forecasting of EV Charging Sites: Deep Transfer Learning with Multi-Quantile Temporal Convolutional Network*. DOI: 10.48550/arXiv.2409.11862. arXiv: 2409.11862 [cs.LG].
- Amara-Ouali, Yvenn, Bachir Hamrouche, Guillaume Principato und Yannig Goude (2025). „Quantifying the Uncertainty of Electric Vehicle Charging with Probabilistic Load Forecasting“. In: *World Electric Vehicle Journal* 16.2, S. 88. DOI: 10.3390/wevj16020088.
- Bishop, Christopher M. (2006). *Pattern Recognition and Machine Learning*. New York: Springer.
- Breiman, Leo, Jerome H. Friedman, Richard A. Olshen und Charles J. Stone (1984). *Classification and Regression Trees*. Belmont, CA: Wadsworth.
- dida (2026). *Was ist ein LSTM neuronales Netzwerk?* Abbildung. dida Datenschmiede GmbH. URL: <https://dida.do/de/was-ist-ein-lstm-neuronales-netzwerk> (besucht am 09.07.2026).
- Gaete-Morales, Carlos, Hendrik Kramer, Wolf-Peter Schill und Alexander Zerrahn (2020). *emobpy: A Tool for Generating Battery Electric Vehicle Time Series*. Synthetische BEV-Profil auf Basis deutscher Mobilitätsstatistik (MiD). DOI: 10.5281/zenodo.3931663.
- (2021). „An open tool for creating battery-electric vehicle time series from empirical data, emobpy“. In: *Scientific Data* 8.1. Peer-reviewtes Paper zum emobpy-Tool; Begleitsoftware siehe Gaete-Morales, Kramer, Schill und Zerrahn 2020, S. 152. DOI: 10.1038/s41597-021-00932-9. URL: <https://www.nature.com/articles/s41597-021-00932-9> (besucht am 15.07.2026).
- Géron, Aurélien (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. 3. Aufl. Sebastopol, CA: O'Reilly Media.
- Hastie, Trevor, Robert Tibshirani und Jerome Friedman (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2. Aufl. New York: Springer. DOI: 10.1007/978-0-387-84858-7.
- Hyndman, Rob J. und George Athanasopoulos (2021). *Forecasting: Principles and Practice*. 3. Aufl. Melbourne: OTexts. URL: <https://otexts.com/fpp3/> (besucht am 15.06.2026).

- Ji u. a. (2023). „Rethinking the Regularity in Mobility Patterns of Personal Vehicle Drivers: A Multi-city Comparison Using a Feature Engineering Approach“. In: *Transactions in GIS* 27.3, S. 663–685. DOI: 10.1111/tgis.13043.
- Koenker, Roger und Gilbert Bassett (1978). „Regression Quantiles“. In: *Econometrica* 46.1, S. 33–50. DOI: 10.2307/1913643.
- Kumar, Raman und Anuj Jain (2023). „Driving behavior analysis and classification by vehicle OBD data using machine learning“. In: *The Journal of Supercomputing* 79.16, S. 18800–18819. DOI: 10.1007/s11227-023-05364-3.
- Lindroth, Tobias, Axel Svensson, Niklas Åkerblom, Mitra Pourabdollah und Morteza Haghir Chehreghani (2024). „Online Learning Models for Vehicle Usage Prediction During COVID-19“. In: *IEEE Transactions on Intelligent Transportation Systems*. DOI: 10.1109/TITS.2024.3361676.
- Meinshausen, Nicolai (2006). „Quantile Regression Forests“. In: *Journal of Machine Learning Research* 7, S. 983–999. URL: <https://www.jmlr.org/papers/v7/meinshausen06a.html>.
- Oh, Geunseob, David J. LeBlanc und Huei Peng (2022). „Vehicle Energy Dataset (VED), A Large-scale Dataset for Vehicle Energy Consumption Research“. In: *IEEE Transactions on Intelligent Transportation Systems* 23.4. Daten: <https://github.com/gsoh/VED>, S. 3302–3312. DOI: 10.1109/TITS.2020.3035596.
- others, and (2025). „Individual Mobility Prediction by Considering Current Traveling Features and Historical Activity Chain“. In: *Geo-spatial Information Science*, S. 2988–3015. DOI: 10.1080/10095020.2025.2455005.
- Pozzato, Gabriele, Anirudh Allam und Simona Onori (2023). *Data from: Analysis and Key Findings from Real-World Electric Vehicle Field Data*. Reale 1-Jahres-Felddaten eines Audi e-tron (CAN-Bus, SOC). DOI: 10.17632/7vdkzpnjgj.2. URL: <https://data.mendeley.com/datasets/7vdkzpnjgj/2> (besucht am 13.06.2026).
- ResearchGate (2021). *Flow Diagram of Gradient Boosting Machine Learning Method*. Abbildung. URL: https://www.researchgate.net/figure/Flow-diagram-of-gradient-boosting-machine-learning-method-The-ensemble-classifiers_fig1_351542039 (besucht am 02.07.2026).
- (2022). *Diagram of the Bagging Technique Used for Classification or Regression Problems in ML*. Abbildung. URL: https://www.researchgate.net/figure/Diagram-of-the-bagging-technique-used-for-classification-or-regression-problems-in-ML_fig1_362065998 (besucht am 02.07.2026).
- Sanami, Saba, Hesam Mosalli, Yu Yang, Hen-Geul Yeh und Amir G. Aghdam (2025). *Demand Forecasting for Electric Vehicle Charging Stations using Multivariate Time-Series Analysis*. DOI: 10.48550/arXiv.2502.16365. arXiv: 2502.16365 [cs.LG].

- Schilli, Michael (2017). „KI lernt mit Entscheidungsbaeumen“. In: *Linux-Magazin* 08. URL: <https://www.linux-magazin.de/ausgaben/2017/08/snapshot/> (besucht am 13.06.2026).
- ScienceDirect (2026). *Light Gradient Boosting Machine*. Abbildung. ScienceDirect Topics, Engineering. URL: <https://www.sciencedirect.com/topics/engineering/light-gradient-boosting-machine> (besucht am 03.07.2026).
- Su, Zhihan, Xiaochen Liu, Hao Li, Tao Zhang, Xiaohua Liu und Yi Jiang (2025). „A vehicle trajectory-based parking location recognition and inference method: Considering both travel action and intention“. In: *Sustainable Cities and Society* 119, S. 106088. DOI: 10.1016/j.scs.2024.106088.
- Wuttke, Laurenz (2024). *Machine Learning: Algorithmen, Methoden und Beispiele*. Datasolut GmbH. URL: <https://datasolut.com/was-ist-machine-learning/> (besucht am 13.06.2026).
- Yabe, Takahiro, Kota Tsubouchi, Toru Shimizu, Yoshihide Sekimoto, Kaoru Sezaki, Esteban Moro und Alex Pentland (2024). „YJMob100K: City-scale and longitudinal dataset of anonymized human mobility trajectories“. In: *Scientific Data* 11.1, S. 397. DOI: 10.1038/s41597-024-03237-9.

A. Anhang

A.1. Zusätzliche Abbildungen

TODO: Zusätzliche Abbildungen hier einfügen, falls vorhanden.

A.2. Zusätzliche Tabellen

TODO: Zusätzliche Tabellen hier einfügen, falls vorhanden.

A.3. Quellcode

TODO: Relevanten Quellcode hier einfügen, falls vorhanden.

Eidesstattliche Erklärung

Ich versichere hiermit, dass ich die vorliegende Masterarbeit mit dem Titel

Titel der Masterarbeit

selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten oder unveröffentlichten Schriften entnommen sind, sind als solche kenntlich gemacht. Die Arbeit hat in gleicher oder ähnlicher Form noch keiner anderen Prüfungsbehörde vorgelegen.

.....
Ort, Datum

.....
Unterschrift