

Hochschule Esslingen

Fakultät für Informatik

Masterarbeit

Prognose individuellen Mobilitätsverhaltens auf Basis eines mit Bewegungsdaten trainierten Machine-Learning-Modells

Achim Baumgärtner

Matrikelnummer: 766010

Erstgutachter: Prof. Dr. Sonntag

Zweitgutachter: Prof. Dr. Schober

Esslingen am Neckar, 3. Juni 2026

Eidesstattliche Erklärung

Ich versichere hiermit, dass ich die vorliegende Masterarbeit mit dem Titel

Titel der Masterarbeit

selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten oder unveröffentlichten Schriften entnommen sind, sind als solche kenntlich gemacht. Die Arbeit hat in gleicher oder ähnlicher Form noch keiner anderen Prüfungsbehörde vorgelegen.

.....
Ort, Datum

.....
Unterschrift

Kurzfassung

TODO: Kurzfassung sollte das Thema, die Methodik, die wichtigsten Ergebnisse und die Schlussfolgerungen in ca. 150–300 Wörtern zusammenfassen.

- ziel
- datenbasis
- methode
- ergebnisse
- beitrag

Die Auswertung fahrzeugspezifischer Daten ermöglicht es, bei kontinuierlichen Nutzungsmustern das Bewegungsverhalten vorherzusagen. Dadurch kann bidirektionales Laden effizienter eingesetzt werden, was sowohl die Fahrzeughalter als auch das Stromnetz entlastet.

Schlüsselwörter: Schlüsselwort 1, Schlüsselwort 2, Schlüsselwort 3

Abstract

TODO: Insert the English abstract here. The abstract should summarize the topic, methodology, key results, and conclusions in approx. 150–300 words.

Keywords: Keyword 1, Keyword 2, Keyword 3

Inhaltsverzeichnis

Eidesstattliche Erklärung	i
Kurzfassung	ii
Abstract	iii
Abbildungsverzeichnis	vi
Tabellenverzeichnis	vii
0.0.1. Lag	0
0.0.2. Rolling	0
0.0.3. Feature Sicherung	0
0.0.4. Robustheit	0
1. Einleitung	4
1.1. Motivation	4
1.2. Problemstellung	5
1.3. Zielsetzung	6
1.4. Forschungsfragen	6
1.5. Aufbau der Arbeit	7
2. Theoretische Grundlagen	8
2.1. Verarbeitung von Mobilitätsdaten	8
2.2. Bewertung der Datenqualität	8
2.3. Stand der Forschung	8
2.3.1. Mobilitäts- und Nutzungsforecast	8
2.4. Verwandte Arbeiten	9
2.5. Zusammenfassung	10
3. Methodik	11
3.1. Forschungsdesign	11
3.2. Vorgehen	11
3.3. Datenerhebung	11
3.4. Datenanalyse	12

3.5. Zusammenfassung	12
4. Implementierung	13
4.1. Systemarchitektur	13
4.2. Technologieauswahl	13
4.3. Umsetzung	13
4.4. Herausforderungen	13
4.5. Zusammenfassung	13
5. Evaluation	14
5.1. Evaluationsdesign	14
5.2. Testumgebung	14
5.3. Ergebnisse	14
5.4. Zusammenfassung	14
6. Diskussion	15
6.1. Interpretation der Ergebnisse	15
6.2. Vergleich mit verwandten Arbeiten	15
6.3. Limitationen	15
6.4. Implikationen	15
7. Fazit und Ausblick	16
7.1. Zusammenfassung	16
7.2. Beantwortung der Forschungsfragen	16
7.3. Ausblick	16
Literaturverzeichnis	17
A. Anhang	18
A.1. Zusätzliche Abbildungen	18
A.2. Zusätzliche Tabellen	18
A.3. Quellcode	18

Abbildungsverzeichnis

Tabellenverzeichnis

2.1. Zentrale Forschungsstränge im Umfeld der individuellen Fahrzeugnut-	
zungsprognose.	9
2.2. Fünf Fahrertypen des Individualverkehrs nach Ji u. a. (2023).	9

TODO:

0.0.1. Lag

0.0.2. Rolling

0.0.3. Feature Sicherung

0.0.4. Robustheit

- Robustheit gegenüber unvollständigen Daten
- Robustheit gegenüber fehlerhaften Daten
- Robustheit gegenüber unregelmäßigen Daten
 - Drop von Datenpunkten bei fehlerhaften werten

2026-05-26 — Multi-Trip-Auflösung pro Tag Die bisherige Tageskarte fasste einen Tag auf eine einzige Abfahrt/Rueckkehr-Spanne zusammen (**depEst** = erste aktive Stunde, **retEst** = letzte). Damit gingen die realistischen Tagesmuster eines Nutzers verloren: morgens zur Arbeit, mittags Lunch, abends Freizeit — drei diskrete Trips, im Heatmap-Grid sichtbar, aber im Day-Card unsichtbar.

Eingefuehrt: Backend-Helper `_extract_trips` extrahiert zusammenhaengende Aktiv-Blocke aus dem stueendlichen Forecast-Grid (Threshold = adaptive Schwelle aus Fix 2). Jede Day-Card traegt jetzt `trips[]` mit `starth`, `endh`, `durationh`, `peakP`, `meanP` und P10/P90 pro Block. Das Frontend rendert die Trips als horizontale Kartenleiste pro Tag.

Limitierung: die Auflösung bleibt bei 1 Stunde, weil `data_adapters.py` die Zeitstempel beim Laden auf `.dt.floor("h")` diskretisiert. Sub-Stunden-Präzision waere nur ueber Aenderung der Datenpipeline (raw timestamps fuer routine und VED erhalten) oder durch Interpolation moeglich; letzteres haetten wir abgelehnt, weil es kuenstliche Genauigkeit suggerieren wuerde. UI macht das jetzt transparent (“Auflösung: 1 Stunde”) statt 5.0 als Zeit-Wert zu zeigen.

2026-05-26 — Drei Fixes gegen Forecast-Kollaps bei niedriger Basisrate

Diagnose nach den ersten Hourly-Forecast-Laeufen: nur `routine` liefert sinnvolle Aktiv-Fenster, `emobpy`, `realworlddev` und `ved` produzieren `pUsed=0.0` durchgaengig. Ursache war eine Kombination aus Klassen-Imbalance (Aktiv-Rate 3-10%) und selbstverstaerkendem autoregressiven Kollaps im Monte-Carlo-Rollout: fruehe Bernoulli-Nullen erzeugen Lag-Werte gleich Null, was die Wahrscheinlichkeit weiter senkt. Drei Aenderungen:

- **Klassengewichtung:** `class_weight="balanced"` im Hourly-Classifer beider Forecaster (RF und LGBM). Hebt die Minderheits-Klassen-Wahrscheinlichkeiten in den kalibrierten Bereich.
- **Adaptive Aggregations-Schwelle:** statt fixem `p_mean ≥ 0.5` jetzt `p_mean ≥ clamp(1.5 · base_rate, 0.30, 0.60)`. Niedrigaktive Fahrzeuge erhalten damit Sinn-Aussagen, hochaktive (Pendler) werden nicht uebersaettigt.
- **Soft-Mode:** optionaler deterministischer Rollout-Pfad. Statt Bernoulli-Sampling wird die kontinuierliche Wahrscheinlichkeit selbst als Lag weitergereicht. Verhindert den Sample-Kollaps, kostet aber die Quantil-Streuung ($P_{10} = P_{50} = P_{90} = \text{mean}$). Frontend-Toggle in der Sidebar; Default bleibt Monte-Carlo wegen statistischer Korrektheit.

Methodisch erlaubt der Toggle eine saubere Ablation: *MC* ist die robuste statistische Variante, *Soft* zeigt das Verhalten ohne Sampling-Rauschen. Bei niedrigen Basisraten konvergieren beide auf aehnliche Mittelwerte; bei hohen Basisraten unterscheiden sich nur die Quantile.

2026-05-26 — Auto-regressives Hourly-Forecasting (Hybrid-Pipeline) Der bisherige Day-Forecast lieferte nur ein aggregiertes `pUsed` pro Tag und sagte damit *nicht, wann* ein Fahrzeug genutzt wird — nur *ob* der Tag im Schnitt aktiv ist. Eingefuehrt: `predict_hourly_mc` in `RandomForestForecaster` und `LGBMForecaster`. Beide trainieren ein stuendliches Schwesternmodell auf den gleichen Daten (Features aus `base.py`: `hour`, `weekday`, `is_weekend`, Lags 1/2/24/168, Rolling-Mittel 24 h und 168 h) und persistieren die letzten 168 h des Default-Fahrzeugs als Startpunkt.

Vorhersage erfolgt *auto-regressiv* und *Monte-Carlo*: 100 unabhaengige Sample-Pfade rollen Stunde fuer Stunde vorwaerts, jeweils `Bernoulli(p)` aus der Modell-Wahrscheinlichkeit ziehen und den gezogenen Wert als `lag_1` fuer die naechste Stunde weiterreichen. Pro Forecast-Stunde liefert das einen Mittelwert `p_mean` sowie die Quantile `p10`, `p50`, `p90`. Damit ist die Unsicherheit nicht mehr eine separate Annahme, sondern faellt aus der Sample-Streuung heraus.

Backend (`_to_result`) ist hybrid: Stunden-Grid ist die Quelle der Wahrheit, Tageskarten werden daraus aggregiert (`pUsed` = Anteil Stunden mit `p_mean ≥ 0.5`; `depEst` / `retEst` = erste / letzte solche Stunde; P10/P90-Bands aus den entsprechenden Quantil-Schwellen). Legacy-`.joblib` ohne `hourly_clf` fallen auf den alten Day-Pfad zurueck. Frontend zeigt im Stunden-Forecast-Panel eine Heatmap (Forecast-Tag × Stunde) mit Farbe = `p_mean` und Saettigung = Konfidenz (eng = sicher, blass = breite Sample-Streuung).

Methodisch hat dieser Schritt zwei Konsequenzen: (1) der Vergleich zwischen Datenquellen wird vergleichbar, weil alle nun dieselbe Output-Form haben (P-Vektor mit 168 Einträgen + Quantile); (2) das “ich weiss nicht” der Modelle wird explizit sichtbar — breite P10/P90 zeigen, wann der Forecast *nicht* vertrauenswürdig ist, was eine saubere Diskussionsgrundlage liefert.

2026-05-26 — Training-Reiter im Frontend Neuer Tab `/training` neben Forecast und Einstellungen. Listet pro Datenquelle (`emobpy`, `realworlddev`, `ved`, `routine`) und Algorithmus (`rf`, `lgbm`) eine deskriptive Auswahl, plus Eingaben für `history_days` und (wo sinnvoll) `limit_vehicles`. Triggert `POST /api/train`, das `train_<source>_forecaster.py` als Subprocess startet; Log-Output wird via Polling auf `GET /api/train/{job_id}` in Echtzeit angezeigt. Damit kann die Ablationsstudie auch ohne Terminal-Zugriff ausgeführt werden, was den Dokumentationsaufwand für die Methodik-Sektion reduziert (jeder Lauf hat Job-ID + erhaltener Log).

2026-05-26 — Modul-Reorganisation in forecast/ und classifier/ Die beiden Modellfamilien (binärer Driving-Classifer vs. 1-7-Tage-Forecaster) wurden in eigene Unterordner unter `code/model_scripts/` verschoben. Geteilte Helpers (`base.py`, `data_adapters.py`) bleiben oben. Begründung: klare Trennung der Forschungsschienen — die Cross-Validation- Methodik (Datenqualität, binär) hängt nicht mit der Anwendungs-Schiene (Tages-Forecast, multi-vehicle, Quantile) zusammen.

2026-05-26 — Ablations-Registry und LGBMForecaster Eingeführt: `forecaster_registry` mit Lazy-Import-Lookup `name` → Klasse. Erste Schwesterimplementierung `LGBMForecaster` mit nativer Quantil-Regression (drei separate `LGBMRegressor`en mit `objective="quantile"`, `alpha=0.1/0.5/0.9`) statt RF-Tree-Variance. Damit ist die Ablationsstudie (`LogReg` → `RF` → `LightGBM` → `LSTM` → `TFT`) erweiterbar, ohne Backend, Trainingskripte oder Frontend zu ändern. Backend-Schnittstelle auf `predict_proba_day` + `predict_quantiles` abstrahiert — keine Direkt-Inspektion von `reg.estimators_` mehr.

2026-05-26 — Multi-Vehicle-Forecaster `RandomForestForecaster.fit` akzeptiert jetzt einen `vehicle_id`-mehrwertigen Eingabe-Frame. Trainingszeilen kommen aus allen Fahrzeugen (Lag-Fenster überschreiten nie Fahrzeug-Grenzen). Für `predict()` wird das aktivste Fahrzeug mit `jüngstem timestamp.max()` als

Default ausgewählt; dessen Daily-Slice wird in `self.daily` persistiert. Das 7×24 -Stundenprofil mittelt mit gleichem Gewicht über alle Fahrzeuge, damit langlebigere Zeitreihen nicht dominieren. Erlaubt einen einzigen Forecaster pro Multi-Vehicle-Quelle (`emobpy`, `ved`).

2026-05-26 — Run-Verzeichnis-Schema Jede Forecast-Erzeugung schreibt in `predictions/<modell>/<datensatz>_<N>d_T<DD-MM-YYYY>/`. Ein Run ist damit ein vollständiges Verzeichnis-Objekt (CSV, Plots, Notizen) und kann über das Frontend in den Store importiert werden. Hinweis: Doppelpunkte sind in Windows-Pfaden verboten, deshalb `T<DD-MM-YYYY>` mit Bindestrich statt `TDD:MM:YYYY`.

2026-05-26 — Forecaster-Familie pro Datenquelle Trainingsskripte `train_<source>_forec` für alle vier Quellen ergänzt. `real_world_ev` ersetzt das frühere `car_full_forecaster` unter konsistentem Namensschema `<source>_forecaster_<algo>.joblib`. Das alte `joblib` bleibt für Backward-Compat erhalten; ein Shim in `model_scripts/csv_forecaster.py` re-exportiert die Klasse unter dem alten Modulpfad, damit `joblib.load` weiterhin funktioniert.

1. Einleitung

Die Elektromobilität ist ein immer wichtiger werdendes Thema. Sie trägt zur Reduzierung von Treibhausgasemissionen bei, verringert die Abhängigkeit zu fossilen Brennstoffen und somit auch wirtschaftliche Abhängigkeiten. Gleichzeitig bietet sie eine neue Möglichkeit bei der Energieversorgung.

Die Möglichkeit bei der Energieversorgung ist hier besonders interessant. Fahrzeuge, die mit Strom betrieben werden, können nicht nur als Verbraucher betrachtet werden, sondern auch als Energiespeicher. Elektrofahrzeuge können also nicht nur Energie aufnehmen, sondern diese auch wieder abgeben, was besonders im Kontext von erneuerbaren Energien von großer Bedeutung ist.

Im Moment bestehen noch kaum rentable Möglichkeiten, überschüssige Energie aus erneuerbaren Quellen zu speichern, weshalb dem Thema eine besondere Relevanz zukommt: Durch eine zuverlässige Speicherung könnte Energie auch dann genutzt werden, wenn Solar- oder Windanlagen nicht aktiv erzeugen. Damit ließe sich der Anteil erneuerbarer Energien an der Versorgung deutlich erhöhen, was ein wichtiger Beitrag zur Energiewende wäre.

Jedoch bringt eine Speicherung von Energie in Elektrofahrzeugen einen geringfügigen Mehrwert - ökonomisch wie auch ökologisch - wenn diese nicht zuverlässig gesteuert wird. Es wird ein System benötigt, das die intelligente Steuerung von Energieflüssen zwischen Fahrzeug und Stromnetz ermöglicht. Eine intelligente Steuerung ist nur möglich, wenn das Nutzerverhalten identifiziert werden kann. Es muss also ein System entworfen werden, das eine zuverlässige Vorhersage über das Mobilitätsverhalten des Nutzers ermöglicht.

1.1. Motivation

In dieser Arbeit wird untersucht, inwiefern sich das Nutzungsverhalten von Elektrofahrzeugen vorhersagen lässt, um potentiell den Energiefluss zwischen Fahrzeug und Stromnetz zu optimieren. Voraussetzung hierfür ist die Verfügbarkeit von V2G (Vehicle-to-Grid), also der Fähigkeit von Elektrofahrzeugen, Energie nicht nur aufzunehmen, sondern auch wieder ans Stromnetz abzugeben. Obwohl V2G

zunehmend an Präsenz gewinnt, bestehen in der praktischen Anwendung weiterhin große Lücken. Ein zentraler Baustein für das effiziente Zusammenwirken von Elektrofahrzeugen und Stromnetz ist ein zuverlässiges Vorhersagemodell des Mobilitätsverhaltens: Es erlaubt, Lade- und Entladezyklen so zu steuern, dass sowohl die Effizienz der mobilen Akkumulatoren als auch die Auslastung des Netzes optimiert werden. Entscheidend ist dabei die Zuverlässigkeit der Vorhersage, um ein fehlerloses System gewährleisten zu können.

1.2. Problemstellung

Die größte Hürde stellt eine stabile Datengrundlage dar. Da der Anwendungsfall sehr anspruchsvoll und dynamisch ist, lässt er sich mit bestehenden Ansätzen bislang nur unzureichend abbilden. Typischerweise erzielen Machine Learning Modelle sehr gute Ergebnisse bei dieser Art von Vorhersageproblemen. Voraussetzung dafür ist allerdings eine hochqualitative Datenbasis, denn Fehleinschätzungen können zu einer fehlerhaften Energieverwaltung und im schlimmsten Fall zur Nichtverfügbarkeit des Fahrzeugs führen. Es müssen also verlässliche Daten über das Mobilitätsverhalten erhoben oder von Dritten bezogen werden. Da Qualität in diesem Bereich nicht genau definiert ist, gilt es dies an bestimmten Kriterien und Werten festzulegen.

In Betrachtung der existierenden wissenschaftlichen Literatur besteht im Moment ein Mangel an Studien, die sich explizit mit dem Mobilitätsverhalten von Individuen und der Erstellung von Prognosemodellen für diesen Zweck beschäftigen. Es gibt wertvolle Studien, die sich mit dem Mobilitätsverhalten von Gruppen beschäftigen, jedoch liefern diese wenig Aufschluss darüber, wie sich der Individualverkehr vorhersagen lässt. Damit künftig eine intelligente Steuerung von Energieflüssen möglich wird, müssen zuverlässige Vorhersagemodelle entwickelt werden, die auf hochqualitativen Daten zum individuellen Mobilitätsverhalten basieren.

Bisherige Arbeiten zur Prognose im Mobilitäts- und Energiekontext konzentrieren sich überwiegend auf den Ladezeitpunkt, die Leistung oder den letztendlichen Ladezustand sowie auf aggregiertes Nutzungsverhalten ganzer Gruppen. Das individuelle Fahr- und Nutzungsverhalten einzelner Fahrzeuge wird dabei kaum modelliert, obwohl gerade dieses für eine genaue Steuerung bzw. Vorhersage von Nöten ist. Wo individuelles Fahrverhalten betrachtet wird, ist es zwischen den Fahrern stark heterogen, sodass ein einzelnes, übergreifendes Modell nicht den kompletten Kontext erfasst; zugleich ist die Datenbasis der wenigen einschlägigen Studien häufig nicht ausreichend oder – wie bei synthetisch erzeugten Profilen –

nicht zuverlässig repräsentativ für reale Mobilitätsdaten. Eine ausführliche Einordnung der relevanten Forschungsstränge und die daraus abgeleitete Forschungslücke finden sich in Section 2.3.

1.3. Zielsetzung

Das Ziel der Arbeit ist es, zuverlässige Modelle zur Prognose für individuelles Mobilitätsverhalten zu entwickeln. Die Modelle sollen den Zweck erfüllen, genauer Uhrzeiten vorhersagen zu können, wann ein Fahrzeug fährt und wann es parkt. Beispielsweise soll ein Modell, für bis zu sieben Tage, Dazu sind die erhobenen Daten, qualitativ zu bewerten und wenn nötig, aus Datenschutzgründen zu anonymisieren. Auf dieser Grundlage werden Modelle erstellt, die das Mobilitätsverhalten von Nutzern möglichst genau vorhersagen können. Des Weiteren soll Gegenstand der Arbeit sein, die Vorhersagegenauigkeit verschiedener Modelle zu vergleichen und deren Einflussfaktoren zu quantifizieren. Die Ergebnisse sollen dazu beitragen, eine intelligente Steuerung von Energieflüssen zwischen Fahrzeug und Stromnetz zu ermöglichen, um so die Nutzung von erneuerbaren Energien zu verbessern und eine wichtige Rolle bei der Energiewende zu spielen.

1.4. Forschungsfragen

1. Wie zuverlässig lässt sich das individuelle Mobilitätsverhalten einzelner Fahrzeuge über einen Horizont von bis zu sieben Tagen vorhersagen?
 - a) Wie unterscheiden sich verschiedene Verfahren des maschinellen Lernens hinsichtlich ihrer Vorhersagegenauigkeit?
 - i. Welchen Einfluss hat die Datenqualität bzw. -quelle auf die Prognosegüte – getrennt vom Einfluss des gewählten Algorithmus?
 - b) Welche Merkmale beeinflussen das individuelle Mobilitätsverhalten am stärksten?
2. Welche Anforderungen an die Datengrundlage ergeben sich daraus, und wie lässt sich ihre Qualität bewerten?
 - a) Wie wirken sich Aufbereitung und eine aus Datenschutzgründen notwendige Anonymisierung auf die Nutzbarkeit der Daten aus?

1.5. Aufbau der Arbeit

TODO: nochmal überschauen/bearbeiten*

Die vorliegende Arbeit ist wie folgt aufgebaut:

Chapter 2 erläutert die theoretischen Grundlagen, die für das Verständnis dieser Arbeit notwendig sind.

Chapter 3 beschreibt die gewählte Methodik und das Vorgehen.

Chapter 4 stellt die Implementierung der entwickelten Lösung vor.

Chapter 5 präsentiert die Evaluation und die erzielten Ergebnisse.

Chapter 6 diskutiert die Ergebnisse und deren Bedeutung.

Chapter 7 fasst die Arbeit zusammen und gibt einen Ausblick auf zukünftige Arbeiten.

2. Theoretische Grundlagen

Dieses Kapitel legt die Grundlagen, auf denen die folgende Methodik aufbaut. Zunächst wird betrachtet, wie Mobilitätsdaten verarbeitet werden (Section 2.1) und anhand welcher Kriterien sich ihre Qualität bewerten lässt (Section 2.2). Anschließend ordnet Section 2.3 den aktuellen Stand der Forschung ein und arbeitet die Forschungslücke heraus, von der sich diese Arbeit in Section 2.4 abgrenzt.

2.1. Verarbeitung von Mobilitätsdaten

2.2. Bewertung der Datenqualität

2.3. Stand der Forschung

Die Forschung zur Prognose individueller Fahrzeugnutzung lässt sich grob in mehrere Stränge gliedern, die sich in Zielgröße, Methodik und Datengrundlage unterscheiden. Tabelle 2.1 fasst diese Stränge als Übersicht zusammen; die folgenden Unterabschnitte vertiefen sie jeweils und arbeiten am Ende die für diese Arbeit zentrale Forschungslücke heraus.

TODO: Aktuellen Stand der Forschung zusammenfassen. Welche verwandten Arbeiten gibt es? Was wurde bereits untersucht? Pro Tabellenzeile eine Subsection mit synthetisierter Quellenlage anlegen, abschließend Forschungslücke formulieren.

2.3.1. Mobilitäts- und Nutzungsforecast

Ein zentraler Befund dieses Strangs betrifft die Heterogenität individuellen Fahrverhaltens. Ji u. a. (2023) werten über vier Millionen Fahrten von 3743 privaten Fahrzeugführern in sechs US-Metropolregionen aus und zeigen, dass sich die Fahrer in fünf deutlich verschiedene Typen gliedern lassen (Table 2.2), die sich vor allem in ihrer Pendelregelmäßigkeit und im Anteil nicht-arbeitsbezogener Fahrten

Forschungsstrang	Typische Methoden	Metho-	Datengrundlage	Offene Punkte
Mobilitäts- und Nutzungsforecast	Statistische Modelle (ARIMA), Random Forest, neuronale Netze (LSTM)	Modelle	Reale und Telematik-Bewegungsdaten	Generalisierung über Fahrzeuge und Quellen hinweg
Driving-/Parking-Klassifikation	Random Forest, SVM, Gradient Boosting	Forest, Gradient	EV-Flottendaten, stündliche Profile	Einfluss der Datenqualität auf die Klassifikationsgüte
EV-Last- und Ladeprognose	Gradient Boosting, Deep Learning	Boosting,	Synthetische Daten (z. B. emobpy), reale EV-Daten	Vergleichbarkeit synthetischer und realer Datengrundlagen
Unsicherheits- und Quantilsprognose	Quantilsregression, Quantile-Random-Forest	Quantile-Random-Forest	Heterogene Mobilitätsdaten	Kalibrierung individueller Vorhersageintervalle (P10/P90)

Tabelle 2.1.: Zentrale Forschungsstränge im Umfeld der individuellen Fahrzeugnutzungsprognose.

unterscheiden. Diese Heterogenität erklärt, warum ein einzelnes, übergreifendes Modell dem Individualverkehr nur begrenzt gerecht wird, und motiviert eine individuelle bzw. quellenspezifische Modellierung.

Fahrertyp	Charakterisierung
Homebodies	Wenigfahrer, die nur kurz und selten das Haus verlassen; geringe Mobilität.
Gig Drivers	Fahrer mit hohem, auftragsgetriebenem Fahraufkommen (z. B. Liefer- und Fahrdienste) ohne festen Arbeitsort.
Movers	Individuen mit breit gestreutem Fahrverhalten und vielen wechselnden Zielen, ohne klares Muster.
Typical Drivers	Durchschnittsfahrer mit einer Mischung aus Arbeits- und Freizeitfahrten und mittlerer Regelmäßigkeit.
Work-focused Commuters	Berufspendler mit stark regelmäßigem Pendelmuster, wenig nicht-arbeitsbezogenen Fahrten und hoher Vorhersagbarkeit.

Tabelle 2.2.: Fünf Fahrertypen des Individualverkehrs nach Ji u. a. (2023).

2.4. Verwandte Arbeiten

TODO: Verwandte Arbeiten vorstellen und voneinander abgrenzen. Wie unterscheidet sich die eigene Arbeit?

- Forschungsarbeit/SUMO
- ähnliche Studien
-

2.5. Zusammenfassung

TODO: Kurze Zusammenfassung der wichtigsten Erkenntnisse aus diesem Kapitel.

3. Methodik

TODO: Einleitenden Text verfassen. Warum wurde die gewählte Methodik verwendet?

- verschiedene modelle gegenüberstellen
- finetuning von modellen
- datenlage
- preprocessing von daten
- behandlung von sonderbaren werten (entfernen, stärker repräsentieren, etc.)
- robustheit von modell testen/erhöhen
- ausgesuchtes netz anpassen, architektur anpassen, etc.
- erklärung für modelle, versuche usw

3.1. Forschungsdesign

TODO: Das übergeordnete Forschungsdesign beschreiben (z. B. qualitativ, quantitativ, Mixed-Methods, Design Science Research, etc.).

3.2. Vorgehen

TODO: Detailliertes Vorgehen beschreiben. Welche Schritte wurden in welcher Reihenfolge durchgeführt?

3.3. Datenerhebung

TODO: Wie wurden die Daten erhoben? Welche Quellen, Werkzeuge oder Methoden wurden eingesetzt?

3.4. Datenanalyse

TODO: Wie wurden die erhobenen Daten analysiert? Welche Analysemethoden kommen zum Einsatz?

3.5. Zusammenfassung

TODO: Kurze Zusammenfassung der Methodik.

4. Implementierung

TODO: Einleitenden Text verfassen. Was wird in diesem Kapitel vorgestellt?

4.1. Systemarchitektur

TODO: Die Gesamtarchitektur des Systems beschreiben. Welche Komponenten gibt es und wie interagieren sie?

4.2. Technologieauswahl

TODO: Welche Technologien, Frameworks, Programmiersprachen und Werkzeuge wurden eingesetzt und warum?

4.3. Umsetzung

TODO: Zentrale Aspekte der Implementierung beschreiben. Wichtige Algorithmen, Datenstrukturen oder Designentscheidungen erläutern.

4.4. Herausforderungen

TODO: Welche Herausforderungen traten bei der Implementierung auf? Wie wurden sie gelöst?

4.5. Zusammenfassung

TODO: Kurze Zusammenfassung der Implementierung.

5. Evaluation

TODO: Einleitenden Text verfassen. Was wird evaluiert und mit welchem Ziel?

5.1. Evaluationsdesign

TODO: Das Design der Evaluation beschreiben. Welche Metriken, Kriterien oder Hypothesen werden überprüft?

5.2. Testumgebung

TODO: Die Testumgebung beschreiben (Hardware, Software, Datensätze, Konfigurationen).

5.3. Ergebnisse

TODO: Die Ergebnisse der Evaluation präsentieren. Tabellen und Grafiken verwenden.

5.4. Zusammenfassung

TODO: Kurze Zusammenfassung der Evaluationsergebnisse.

6. Diskussion

TODO: Einleitenden Text verfassen. Was wird in diesem Kapitel diskutiert?

6.1. Interpretation der Ergebnisse

TODO: Die Ergebnisse aus Chapter 5 interpretieren. Was bedeuten die Ergebnisse im Kontext der Forschungsfragen?

6.2. Vergleich mit verwandten Arbeiten

TODO: Wie verhalten sich die Ergebnisse im Vergleich zu verwandten Arbeiten aus Section 2.4?

6.3. Limitationen

TODO: Welche Einschränkungen hat die Arbeit? Was konnte nicht untersucht werden? Welche Annahmen wurden getroffen?

6.4. Implikationen

TODO: Welche praktischen und theoretischen Implikationen ergeben sich aus den Ergebnissen?

7. Fazit und Ausblick

7.1. Zusammenfassung

TODO: Die gesamte Arbeit kurz zusammenfassen. Welche Forschungsfragen wurden beantwortet? Was sind die zentralen Ergebnisse?

7.2. Beantwortung der Forschungsfragen

TODO: Jede Forschungsfrage aus Section 1.4 explizit beantworten.

1. **TODO:** Antwort auf Forschungsfrage 1
2. **TODO:** Antwort auf Forschungsfrage 2
3. **TODO:** Antwort auf Forschungsfrage 3

7.3. Ausblick

TODO: Welche zukünftigen Arbeiten könnten auf dieser Arbeit aufbauen? Welche offenen Fragen bleiben bestehen?

Literaturverzeichnis

Ji u. a. (2023). „Rethinking the Regularity in Mobility Patterns of Personal Vehicle Drivers: A Multi-city Comparison Using a Feature Engineering Approach“. In: *Transactions in GIS* 27.3, S. 663–685. DOI: [10.1111/tgis.13043](https://doi.org/10.1111/tgis.13043).

A. Anhang

A.1. Zusätzliche Abbildungen

TODO: Zusätzliche Abbildungen hier einfügen, falls vorhanden.

A.2. Zusätzliche Tabellen

TODO: Zusätzliche Tabellen hier einfügen, falls vorhanden.

A.3. Quellcode

TODO: Relevanten Quellcode hier einfügen, falls vorhanden.